

CAFÉ CEREZA

- Página web con sistema de reservaciones para una cafetería universitaria -



Analítica de Datos para Negocios Digitales

Bitácora de Errores y Pruebas de Validación

Evaluación del estado inicial, trazabilidad de transformaciones, pruebas finales y conservación de transacciones

1. Introducción

La bitácora de errores constituye un mecanismo de trazabilidad para registrar qué problemas existían en los datos de entrada, qué transformaciones fueron aplicadas y cuál fue el resultado observable después del proceso ETL. En Café Cereza, esta documentación es necesaria porque los datos alimentan análisis de ventas, reservaciones, comportamiento de clientes, indicadores y tableros administrativos; por tanto, una corrección incorrecta puede modificar el significado de una transacción o eliminar información válida.

Las pruebas posteriores a la transformación permiten verificar no sólo que disminuyan errores evidentes, sino también que se conserve la estructura transaccional. En este análisis se distingue expresamente entre la entrada del ETL (dataset_ventas_sucio.csv), la referencia ideal de generación (dataset_ventas_limpio.csv) y el resultado real implementado (dataset_maestro_limpio.csv).

2. Objetivo

Documentar los errores originales, las transformaciones realmente ejecutadas, las correcciones obtenidas, los problemas pendientes y las pruebas finales de validación, determinando de forma objetiva si el resultado del ETL mejora la calidad sin introducir una pérdida injustificada de transacciones.

3. Metodología

Se compararon los tres archivos a nivel de filas, identificadores, nulos, dominios, relaciones entre producto y categoría, rangos y consistencia matemática. Las reglas se tomaron del generador de ventas, del diccionario de datos y de los scripts SQL. Para la trazabilidad del ETL se revisó la secuencia efectiva de operaciones del proceso de limpieza: eliminación de filas duplicadas, eliminación por correo, normalización de textos, tratamiento del tiempo de entrega, ajuste de correo, conversión de fecha de registro, filtrado por total y cantidad, y anonimización.

El generador establece 1,500 pedidos, 250 clientes, operación entre 2025-01-01 y 2026-08-19, cantidades de 1 a 3, calificaciones de 1 a 5 y tiempos de entrega de 8 a 45 minutos cuando aplican. Asimismo, genera intencionalmente nulos, duplicados, formatos de fecha heterogéneos, categorías alteradas, rangos inválidos, outliers, campos incompletos y representaciones booleanas inconsistentes.

4. Inventario de errores iniciales

Tipo	Campo/área	Evidencia en entrada
Nulos	Campos afectados	Correo 353; precio 280; método de pago 283; tiempo de entrega 837; calificación 1,332; además de nulos contextuales en mesa/reservación.
Duplicados	Fila / id_venta	26 filas exactamente duplicadas; 187 repeticiones de id_venta.
Textos incompletos	Nombre/correo/producto/ubicación	165 nombres, 438 correos, 165 productos y 2,135 ubicaciones se identifican como nulos o marcadores incompletos; en ubicación gran parte corresponde también a pedidos sin mesa.
Categorías	categoria_producto	472 valores fuera del catálogo exacto.
Producto-categoría	Relación	538 pares no coinciden con el catálogo al considerar registros no nulos.
Canal	canal_venta	236 valores fuera del dominio exacto.
Estado pedido	estado_pedido	236 valores fuera del dominio exacto.
Cantidad	cantidad	141 valores fuera de 1–3.
Precio	precio_unitario	166 negativos y 280 nulos.
Calificación	calificacion_servicio	141 valores no nulos fuera de 1–5.
Tiempo entrega	tiempo_entrega_min	94 valores no nulos fuera de 8–45.
Booleanos	con_reservacion	159 representaciones textuales alternativas además de True/False.
Montos alterados	subtotal/total	110 id_venta presentan subtotal_pedido/total_pedido diferentes de la referencia al comparar la primera aparición por id_venta; el generador documenta outliers y ventas fantasma.
Fechas	Tres campos	Se introducen formatos heterogéneos. La conversión automática sin formato explícito no permite tratar toda falta de parseo como fecha inválida real; requiere revisión por formato.

5. Bitácora

ID	Campo	Error	Casos	Acción aplicada	Resultado	Estado
E01	Fila completa	Duplicado exacto	26	drop_duplicates()	26 eliminadas	Corregido
E02	correo_cliente	Correo repetido	3,660 eliminaciones adicionales tras E01	Conservar primera fila por correo	Dataset baja de 3,915 a 255 filas	Requiere revisión
E03	Campos texto	Mayúsculas/espacios	Aplicado a todas las columnas texto	strip + minúsculas	Normalización general	Parcialmente corregido
E04	tiempo_entrega_min	Nulos	837 en entrada	Relleno con 15	En maestro: 0 nulos	Corregido
E05	correo_cliente	Dominio correo.com	Presente en datos	Sustituir por gmail.com	Aplicado antes de anonimizar	No aplicable
E06	fecha_registro_cliente	Formato heterogéneo	Casos detectables	Conversión a fecha y YYYY-MM-DD	Maestro: 0 formatos no estándar entre no nulos; 4 nulos	Parcialmente corregido
E07	total_pedido/cantidad	Valores <= 0	8 filas dentro de las 255 restantes	Filtrar total>0 y cantidad>0	255 a 247 filas	Corregido
E08	Datos personales	id/nombre/correo	3 campos identificables	Hash de id_cliente y eliminación de 3 campos	cliente_id_anon presente	Corregido
E09	categoria_producto	Typos	472 en entrada	Sin corrección específica	21 valores inválidos en maestro	No corregido
E10	precio_unitario	Negativos/nulos	166 negativos; 280 nulos	Sin corrección específica	14 negativos y 20 nulos en maestro	No corregido
E11	calificacion_servicio	Fuera de 1–5	141	Sin corrección específica	9 inválidos en maestro	No corregido
E12	con_reservacion	Booleanos inconsistentes	159 formas alternativas	Sólo minúsculas por normalización general	Persisten sí/no/1/0/n	No corregido

6. Trazabilidad de correcciones

- Duplicados exactos → detección con duplicación de fila completa → eliminación de filas repetidas → 26 registros afectados → se eliminan duplicados exactos.
- Correo repetido → detección por correo_cliente → conservación de la primera aparición → 3,660 registros eliminados después de quitar duplicados exactos → reducción extrema de líneas transaccionales.
- Texto heterogéneo → selección de columnas tipo texto → trim y minúsculas → todas las columnas de texto del conjunto intermedio → homogeneización de capitalización, pero no corrección semántica de typos.
- Tiempo de entrega nulo → detección isna → relleno con 15 → aplicado en el conjunto reducido → maestro sin nulos en tiempo_entrega_min; la regla no distingue si el nulo era legítimo por estado del pedido.
- Fecha de registro → detección por patrón → conversión con errores a nulo y salida YYYY-MM-DD → campo fecha_registro_cliente → estandarización parcial.
- Total/cantidad no positivos → filtro total_pedido > 0 y cantidad > 0 → 8 registros del conjunto de 255 → 247 registros finales.
- Datos personales → identificación de id_cliente, nombre_cliente y correo_cliente → hash de id_cliente y eliminación de los tres originales → 247 filas → anonimización observable en el maestro.

7. Registros eliminados

Criterio de eliminación	Registros eliminados	Justificación técnica	Riesgo de pérdida válida
Duplicado exacto	26	La fila completa se repite.	Bajo: coincide con duplicidad exacta.
Correo repetido	3660	Se conserva sólo la primera fila por correo después de retirar duplicados exactos.	Crítico: un cliente puede realizar múltiples pedidos y un pedido puede contener múltiples líneas; el correo no identifica una venta.

total_pedido <= 0 o cantidad <= 0	8	Filtro explícito aplicado sobre las 255 filas restantes.	Medio: cantidad <=0 es inválida según generador; total=0 fue introducido como error, pero la eliminación debe trazarse por id para justificar cada caso.
Total eliminado desde entrada	3694	Diferencia 3,941 - 247.	Crítico: no equivale automáticamente a 3,694 errores corregidos.

8. Pruebas de validación

ID	Prueba / regla	Registros evaluados	Errores	Estado
P01	Sin filas exactamente duplicadas	247	0	APROBADA
P02	id_venta único	247	0	APROBADA
P03	id_pedido como PK de línea	247	No aplica: cada fila final corresponde a pedido distinto	APROBADA CON OBSERVACIONES
P04	Categoría en catálogo	247	21	NO APROBADA
P05	Producto ↔ categoría	237	25	NO APROBADA
P06	Cantidad 1–3	247	9	NO APROBADA
P07	Precio no negativo y presente	247	34	NO APROBADA
P08	Calificación 1–5 cuando existe	168	9	NO APROBADA
P09	Tiempo 8–45 cuando existe	247	4	NO APROBADA
P10	Canal en dominio	247	9	NO APROBADA
P11	Estado pedido en dominio	247	4	NO APROBADA
P12	Método pago en dominio no nulo	223	0	APROBADA CON OBSERVACIONES
P13	Estado pago en dominio	247	0	APROBADA
P14	Fecha registro YYYY-MM-DD si presente	243	0	APROBADA CON OBSERVACIONES
P15	Subtotal línea = cantidad × precio	227	21	NO APROBADA
P16	Total = subtotal pedido + impuestos	247	10	NO APROBADA
P17	Impuestos = 16% subtotal pedido	247	10	NO APROBADA
P18	Anonimización de cliente	247	0	APROBADA

9. Prueba de duplicados

En la entrada existen 26 filas exactamente duplicadas y 187 repeticiones adicionales de id_venta respecto de su unicidad. La referencia ideal tiene 3,754 filas, cero duplicados exactos y cero id_venta repetidos. El maestro tiene 247 filas, cero duplicados exactos y cero id_venta repetidos.

El id_pedido no debe utilizarse como criterio de duplicidad de línea: el generador define una fila como un producto dentro de un pedido y cada pedido puede contener de 1 a 4 líneas. Por ello, los 1,500 pedidos de la referencia se distribuyen en 3,754 líneas legítimas. La ausencia de id_pedido repetidos en el maestro no es una mejora: evidencia que el filtrado por correo destruyó prácticamente toda la estructura multilínea.

10. Prueba de valores nulos

Campo	Nulos en maestro	Evaluación
fecha_registro_cliente	4 (1.62%)	No documentado como opcional en dataset analítico
producto	5 (2.02%)	No documentado como opcional en dataset analítico
precio_unitario	20 (8.10%)	No documentado como opcional en dataset analítico
id_mesa	120 (48.58%)	Contextual
ubicacion_mesa	127 (51.42%)	Contextual
tipo_mesa	120 (48.58%)	Contextual
fecha_reservacion	184 (74.49%)	Contextual
estado_reservacion	186 (75.30%)	Contextual
metodo_pago	24 (9.72%)	No documentado como opcional en dataset analítico
calificacion_servicio	79 (31.98%)	Contextual

Los nulos de mesa y reservación pueden ser legítimos según el tipo de pedido; la calificación también puede faltar cuando el pedido no fue entregado. En cambio, el modelo relacional define precio unitario y método de pago como no nulos. El maestro conserva 20 precios nulos y 24 métodos de pago nulos. El proceso de limpieza no corrige estos campos.

11. Prueba de fechas

El proceso sólo estandariza `fecha_registro_cliente`. En el maestro, los 243 valores no nulos de ese campo cumplen YYYY-MM-DD y permanecen 4 nulos. `fecha_reservacion` conserva 7 valores no nulos fuera del formato YYYY-MM-DD y `fecha_pedido` conserva 29. Por tanto, la estandarización de fechas es parcial.

La coherencia cronológica completa entre registro, reservación y pedido no puede calificarse con una única regla de descarte porque el generador permite reservación el mismo día o hasta tres días antes del pedido, y los formatos heterogéneos pueden ser interpretados de manera ambigua. La validación definitiva de los casos ambiguos requiere parseo explícito por los formatos documentados.

12. Productos y categorías

El catálogo del generador contiene seis categorías y 29 productos. En el maestro permanecen 21 categorías fuera del dominio normalizado y 25 pares producto-categoría no coincidentes entre las 237 filas donde ambos valores están presentes. La normalización a minúsculas no corrige errores como “alimntos”, “resposteria”, “cafe frio” o variantes sin acento; por ello esta prueba no se aprueba.

13. Cantidades

El generador crea cantidades enteras entre 1 y 3. La entrada contiene 141 valores fuera de ese intervalo. El proceso sólo elimina cantidad ≤ 0 en una etapa tardía y no elimina valores excesivos positivos. El maestro conserva 9 cantidades fuera de 1–3, por lo que la validación de rango queda incompleta.

14. Precios

Los precios se generan por categoría dentro de intervalos documentados: Café caliente 28–55; Café frío 35–65; Repostería 25–60; Alimentos 45–95; Bebidas frías 20–40; Bebidas calientes 25–45. La entrada contiene 166 precios negativos y 280 nulos. El maestro conserva 14 negativos y 20 nulos. No existe una transformación específica de precio, por lo que la prueba no se aprueba. La comparación exacta producto-precio no es una regla fija, ya que el generador asigna un precio aleatorio dentro del rango de la categoría en cada línea.

15. Totales

Las fórmulas documentadas son: $\text{subtotal_linea} = \text{cantidad} \times \text{precio_unitario}$; $\text{impuestos} = \text{subtotal_pedido} \times 0.16$; $\text{total_pedido} = \text{subtotal_pedido} + \text{impuestos}$. No se documentan descuentos en los archivos analizados, por lo que su validación es “No determinado a partir de los archivos proporcionados”.

En el maestro se detectan 21 inconsistencias evaluables en `subtotal_linea` frente a `cantidad × precio`, 10 inconsistencias en impuestos frente al 16% del subtotal del pedido y 10 inconsistencias en total frente a subtotal + impuestos. Estas diferencias se explican por errores introducidos en cantidad/precio y por outliers de subtotal/total que el proceso no recalcula.

16. Calificaciones

El generador utiliza calificaciones de 1 a 5 únicamente para pedidos entregados. La entrada contiene 141 calificaciones no nulas fuera de 1–5. El maestro conserva 9 valores fuera del rango. No existe una corrección específica, por lo que la prueba es NO APROBADA.

17. Tiempo de entrega

El generador asigna entre 8 y 45 minutos cuando el estado es entregado o listo; en otros estados el valor puede ser nulo. La entrada contiene 94 valores no nulos fuera de 8–45. El proceso rellena todos los nulos con 15, sin distinguir estado. El maestro queda sin nulos, pero conserva 4 valores fuera del rango. Esta transformación mejora completitud aparente, aunque puede sustituir nulos contextualmente legítimos; por ello requiere observación metodológica.

18. Variables categóricas

Variable	Fuera de dominio en maestro	Observación
canal_venta	9	Persisten tipos/variantes
tipo_pedido	0	Dominio válido
estado_pedido	4	Persisten “entregao”
metodo_pago	0	Dominio válido entre no nulos; 24 nulos
estado_pago	0	Dominio válido
estado_reservacion	0	Dominio válido entre no nulos
ubicacion_mesa	4	Marcadores ??? / sin dato entre valores no nulos
tipo_mesa	0	Dominio válido entre no nulos
tipo_cliente	0	Dominio válido tras normalización a minúsculas

19. Datos personales y anonimización

El maestro elimina id_cliente, nombre_cliente y correo_cliente. En su lugar incorpora cliente_id_anon, construido a partir del identificador del cliente mediante un hash truncado. Se observan 244 identificadores anonimizados únicos en 247 filas. Por tanto, la anonimización implementada sí se refleja en la salida.

Permanecen campos potencialmente indirectos como fecha_registro_cliente y patrones transaccionales. No determinado a partir de los archivos proporcionados si estos campos, combinados con información externa, alcanzan un umbral específico de reidentificación; no existe una evaluación formal de k-anonimato en los archivos analizados.

20. Prueba de conservación de transacciones

Indicador	Sucio	Referencia	Maestro	Resultado
Filas	3941	3754	247	6.27% de la entrada; 6.58% de la referencia
id_venta únicos	3754	3754	247	3,507 id_venta de la referencia no están en el maestro
Pedidos únicos	1500	1500	247	1,253 pedidos de referencia ausentes
Clientes	250	250	244 anonimizados	6 clientes de referencia no representados; 244 clientes conservados
Líneas de detalle	3941 filas de entrada	3754 líneas ideales	247 líneas	La estructura multilínea prácticamente desaparece

La retención del maestro respecto de la entrada es 6.27% y la eliminación es 93.73%. Respecto de la referencia ideal, la retención es 6.58%. La causa dominante es la eliminación por correo: después de retirar 26 duplicados exactos quedan 3,915 filas, pero conservar sólo la primera aparición de cada correo reduce el conjunto a 255. Dado que un cliente puede efectuar múltiples compras y cada pedido puede contener múltiples productos, esas eliminaciones no corresponden exclusivamente a errores. Existe pérdida potencialmente válida de transacciones y líneas de detalle.

21. Comparación con dataset ideal

La referencia ideal conserva 3,754 líneas, 1,500 pedidos y 250 clientes. El maestro conserva 247 líneas y 247 pedidos. Los 247 id_venta del maestro existen en la referencia, pero faltan 3,507 id_venta ideales. Las diferencias por eliminación de id_cliente, nombre y correo son esperadas por anonimización; la conversión de textos a minúsculas también es una transformación esperada. Sin embargo, la reducción a una línea por correo no es necesaria para anonimizar y no está respaldada por la estructura transaccional del generador.

Además, el maestro conserva errores que la referencia no contiene: categorías y canales alterados, cantidades y precios inválidos, inconsistencias matemáticas y formatos de fecha no normalizados. Por ello, el resultado no recupera de forma suficiente la calidad de la referencia ideal.

22. Validaciones SQL

Restricción/validación	Tabla	Campo	Regla	Finalidad
PK / AUTO_INCREMENT	Rol, Usuario, Mesa, Categoria_producto, Bitacora, Producto, Reservacion, Pedido, Detalle_pedido, Pago	id_*	Identificador único por entidad	Integridad de entidad
UNIQUE	Rol	nombre_rol	No repetir nombre de rol	Evitar duplicidad de catálogo
UNIQUE	Usuario	correo	Correo único	Evitar cuentas duplicadas
UNIQUE	Mesa	numero_mesa	Número de mesa único	Identidad física
FK	Usuario	id_rol	Referencia Rol	Integridad referencial
FK	Producto	id_categoria	Referencia Categoria_producto	Integridad referencial
FK	Reservacion	id_usuario / id_mesa	Referencia Usuario / Mesa	Integridad referencial
FK	Pedido	id_usuario / id_mesa / id_reservacion	Referencias correspondientes	Integridad referencial
FK	Detalle_pedido	id_pedido / id_producto	Referencia Pedido / Producto	Integridad referencial
FK	Pago	id_pedido	Referencia Pedido	Integridad referencial
CHECK	Bitacora	tipo_operacion	INSERT, UPDATE o DELETE	Control de dominio
Trigger auditoría	Tablas operativas	INSERT/UPDATE/DELETE	Registrar cambios en Bitacora	Trazabilidad
Trigger protección	Bitacora	UPDATE/DELETE	Bloquea modificación y borrado	Inmutabilidad de auditoría

Los scripts SQL contienen restricciones NOT NULL y claves foráneas, pero no incorporan CHECK para rangos de cantidad, precio, calificación o tiempo de entrega en el dataset analítico. Por ello no se atribuyen al SQL validaciones que no están escritas.

23. Matriz final

ID	Área	Prueba	Resultado	Observación
M01	Duplicados	Sin filas exactas e id_venta único	APROBADA	La eliminación exacta funciona; la eliminación por correo es destructiva.
M02	Nulos	Campos obligatorios completos	NO APROBADA	Persisten precio y método de pago nulos.
M03	Fechas	Formato homogéneo	APROBADA CON OBSERVACIONES	Sólo fecha de registro fue estandarizada.
M04	Catálogo	Producto y categoría válidos	NO APROBADA	Persisten typos y relaciones no recuperadas.
M05	Rangos	Cantidad/precio/calificación/tiempo	NO APROBADA	Persisten valores inválidos.
M06	Matemática	Subtotal/impuestos/total	NO APROBADA	Persisten inconsistencias.
M07	Categóricas	Dominios documentados	NO APROBADA	Persisten canal y estado alterados.
M08	Anonimización	Eliminar identificadores directos	APROBADA	Se sustituyó id_cliente por hash y se retiraron nombre/correo.
M09	Conservación	Preservar transacciones válidas	NO APROBADA	Retención 6.27%; eliminación por correo no representa duplicidad de venta.
M10	SQL	Integridad referencial/auditoría	APROBADA	PK, FK, UNIQUE, CHECK de bitácora y triggers documentados.

24. Porcentaje de aprobación

Se ejecutaron 18 pruebas de la tabla de validación. Se clasificaron 5 como APROBADAS, 3 como APROBADAS CON OBSERVACIONES y 10 como NO APROBADAS. Para evitar inflar el resultado, el porcentaje principal considera únicamente las pruebas plenamente aprobadas: $5 / 18 \times 100 = 27.78\%$.

Las pruebas “APROBADAS CON OBSERVACIONES” no se contabilizan como aprobadas en el porcentaje principal porque presentan limitaciones relevantes. Si se reportara adicionalmente una tasa de cumplimiento no fallido (aprobadas + aprobadas con observaciones), sería $8 / 18 \times 100 = 44.44\%$; esta cifra no sustituye el porcentaje de aprobación estricto.

25. Problemas pendientes

Problema	Evidencia	Impacto	Recomendación
Eliminación por correo	3,660 filas eliminadas tras retirar duplicados exactos	Crítico: pérdida de ventas y líneas legítimas	Eliminar duplicados por identificadores transaccionales y reglas de línea, no por correo.
Categorías/productos no corregidos	21 categorías inválidas y 25 pares producto-categoría no coincidentes en maestro	Alto: segmentación y KPIs por producto/categoría	Aplicar mapeo explícito contra catálogo del generador.
Precios inválidos/nulos	14 negativos y 20 nulos	Alto: distorsión de ingresos y márgenes	Validar rango por categoría y recuperar desde referencia/regla verificable cuando sea posible.
Cantidades inválidas	9 fuera de 1–3	Alto: distorsión de unidades y subtotales	Validar rango 1–3 y no limitarse a cantidad > 0.
Matemática inconsistente	21 líneas y 10 pedidos con inconsistencias	Alto: totales/KPIs incorrectos	Recalcular en orden: línea, subtotal pedido, impuesto y total cuando los insumos sean válidos.
Fechas parcialmente normalizadas	7 reservaciones y 29 pedidos fuera de YYYY-MM-DD entre valores no nulos	Medio: series temporales y filtros	Parsear explícitamente todos los formatos documentados.
Booleanos inconsistentes	Persisten sí/no/1/0/n además de true/false	Medio: filtros y conteos	Mapear todas las representaciones documentadas a booleano real.
Tiempo de entrega imputado indiscriminadamente	Todos los nulos se sustituyen por 15	Medio: sesgo en promedio de entrega	Imputar sólo cuando la ausencia sea un error; conservar nulo cuando el estado no exige tiempo.

26. Resultado general

El dataset maestro supera las pruebas básicas de duplicados exactos, unicidad de id_venta, anonimización y algunos dominios categóricos; sin embargo, no conserva suficiente información transaccional y requiere ajustes importantes antes de alimentar análisis posteriores. La retención de sólo 6.27% de las filas de entrada y 6.58% de las líneas de la referencia ideal es el principal hallazgo de control.

La salida tampoco corrige de manera sistemática categorías, precios, cantidades, calificaciones, tiempos, booleanos ni todas las fechas, y conserva inconsistencias matemáticas. Por ello, aunque existen transformaciones válidas y verificables, el proceso completo no puede considerarse aprobado para un uso analítico confiable sin una revisión del criterio de eliminación por correo y sin completar las validaciones pendientes.

27. Conclusión

El análisis identificó errores iniciales intencionalmente incorporados en el dataset de ventas: nulos, duplicados, formatos heterogéneos, typos, valores fuera de rango, outliers, campos incompletos y booleanos inconsistentes. El proceso ETL corrige duplicados exactos, normaliza parcialmente textos y fecha de registro, elimina algunos valores no positivos y anonimiza identificadores directos. Estas acciones son verificables en el maestro.

No obstante, la eliminación de registros por correo_cliente constituye una transformación destructiva: reduce 3,915 filas posteriores a la deduplicación exacta a 255, aunque el modelo y el generador permiten que un mismo cliente realice múltiples

pedidos y que un pedido tenga varias líneas. Después de filtros adicionales, el maestro termina con 247 filas, frente a 3,754 líneas de la referencia ideal. En consecuencia, una parte sustancial de la pérdida no puede justificarse como corrección de errores.

El porcentaje de aprobación estricto de las pruebas ejecutadas es 27.78%. El estado final se clasifica como REQUIERE AJUSTES antes de utilizar el dataset como fuente principal para KPIs, dashboards o análisis de comportamiento. La prioridad técnica es conservar la granularidad transaccional, redefinir la deduplicación con identificadores adecuados y completar las reglas de validación documentadas.

Fuentes técnicas analizadas

- dataset_ventas_sucio.csv — entrada del ETL.
- dataset_ventas_limpio.csv — referencia/control ideal.
- dataset_maestro_limpio.csv — salida real del proceso implementado.
- Proceso de limpieza Café Cereza — secuencia efectiva de transformaciones y validación.
- generar_dataset_ventas.py — reglas de generación, catálogos, fórmulas y errores intencionales.
- Diccionario_Datos_Cafeteria.docx — entidades, claves, nulabilidad y relaciones.
- script_tablas.sql — restricciones de esquema e integridad referencial.
- script_triggers.sql — auditoría y protección de la bitácora.