

CAFÉ CEREZA

Analítica de Datos para Negocios Digitales

ANÁLISIS EXPLORATORIO DE DATOS (EDA) — CAFÉ CEREZA

Etapa 5 — Análisis Exploratorio de Datos

1. Introducción

El Análisis Exploratorio de Datos (EDA) es la etapa del proceso analítico en la que se examina un conjunto de datos con el propósito de conocer su estructura, calidad, distribución y las relaciones que existen entre sus variables, antes de construir indicadores, modelos o dashboards. A través de estadística descriptiva y visualización de datos, el EDA permite transformar registros numéricos y categóricos, en apariencia dispersos, en información comprensible que respalda la toma de decisiones.

Esta etapa se realiza después de la preparación y limpieza de los datos porque su validez depende directamente de contar con un conjunto de información consistente, sin duplicados, con tipos de datos correctos y con reglas de integridad verificadas. De no partir de un dataset depurado, cualquier estadística o gráfica generada podría inducir a conclusiones erróneas.

Para el caso de Café Cereza, cafetería universitaria que desarrolla una plataforma web con sistema de reservaciones y pedidos anticipados, el EDA aplicado sobre el dataset de ventas simulado permite identificar patrones de comportamiento en clientes, productos, categorías, canales de venta y comportamiento temporal de la demanda. Dado que el negocio se encuentra en una etapa previa a su operación real, este análisis representa además una validación de la coherencia interna de los datos simulados y una práctica metodológica para las siguientes etapas del proyecto.

Los resultados obtenidos en este documento constituyen el insumo base para el cálculo posterior de indicadores clave de desempeño (KPIs), la construcción de un dashboard administrativo y, en general, para fortalecer la toma de decisiones de Café Cereza en materia de inventario, personal, promociones y estrategia de canales.

2. Objetivo del EDA

Objetivo general

Analizar el comportamiento de los datos históricos/simulados de ventas de Café Cereza, contenidos en dataset_ventas_limpio.csv, mediante técnicas estadísticas descriptivas y de visualización de datos, con el fin de identificar patrones, tendencias, relaciones entre variables y oportunidades relevantes que apoyen la toma de decisiones del negocio.

Objetivos específicos

- Evaluar la calidad del dataset, revisando valores nulos, duplicados y datos atípicos.
- Describir el comportamiento individual de las principales variables numéricas y categóricas.
- Comparar variables entre sí para identificar diferencias relevantes por categoría, canal y tipo de cliente.
- Identificar relaciones estadísticas entre variables numéricas mediante un análisis de correlación.
- Estudiar el comportamiento temporal de los pedidos e ingresos a nivel mensual, diario y horario.
- Identificar los periodos de mayor demanda de la cafetería.
- Analizar el desempeño de los productos y categorías del catálogo.
- Analizar el comportamiento de los distintos canales de venta, incluyendo la evolución del canal web.

- Responder, en la medida en que los datos disponibles lo permitan, las preguntas de negocio planteadas en la Etapa 1 del proyecto.

3. Descripción del dataset

El análisis se realizó exclusivamente sobre el archivo `dataset_ventas_limpio.csv`, el cual constituye la versión depurada de los datos de ventas simulados de Café Cereza. Cada fila del archivo representa una línea de producto dentro de un pedido; en consecuencia, un mismo `id_pedido` puede aparecer en varias filas cuando el pedido contiene más de un producto. Para evitar duplicar artificialmente ingresos o conteos de pedidos, el notebook construyó una tabla auxiliar (`pedidos_df`) con un único registro por `id_pedido`, utilizada para todas las métricas a nivel de pedido (ingresos, ticket promedio, tiempo de entrega y calificación), mientras que el dataset completo (`df`) se utilizó para las métricas a nivel de línea de producto (unidades, precio unitario y subtotal de línea).

Tabla 1. Características generales del dataset

Característica	Resultado
Dataset	<code>dataset_ventas_limpio.csv</code>
Registros (líneas de detalle)	3,754
Variables (columnas)	31
Pedidos únicos (<code>id_pedido</code>)	1,500
Cientes únicos (<code>id_cliente</code>)	250
Fecha inicial (<code>fecha_pedido</code>)	03 de enero de 2025
Fecha final (<code>fecha_pedido</code>)	19 de agosto de 2026
Periodo temporal cubierto	Aproximadamente 20 meses
Duplicados exactos	0
Identificadores de venta (<code>id_venta</code>) duplicados	0

La unidad de análisis principal del dataset es la línea de producto dentro de un pedido: cada renglón corresponde a un producto específico solicitado, con su categoría, cantidad y precio unitario, además de información desnormalizada del cliente, del pedido, de la mesa/reservación (cuando aplica) y del pago asociado. En promedio, cada pedido contiene 2.50 líneas de producto y 5.04 unidades vendidas.

4. Metodología del análisis

El análisis exploratorio se desarrolló siguiendo las siguientes etapas, documentadas en el notebook `EDA_Cafe_Cereza_Jupyter.ipynb`:

- 1. Carga del dataset `dataset_ventas_limpio.csv` mediante la librería `pandas`.
- 2. Preparación de variables: conversión de los campos de fecha y hora a tipos de dato temporales.
- 3. Creación de variables temporales derivadas: año, número de mes, nombre de mes, periodo mensual, día de la semana y hora del pedido.

- 4. Creación de una tabla auxiliar (pedidos_df) con un único registro por id_pedido, para evitar duplicar ingresos y conteos de pedidos.
- 5. Revisión de calidad de datos: valores nulos, duplicados y detección de valores atípicos mediante el método del rango intercuartílico (IQR).
- 6. Análisis univariado de variables numéricas y categóricas, incluyendo medidas de tendencia central, dispersión y percentiles.
- 7. Análisis bivariado entre pares de variables relevantes para el negocio (categoría, producto, canal, tipo de cliente, tiempo de entrega, reservaciones).
- 8. Análisis multivariado combinando tres o más variables (mes, canal, categoría, tipo de cliente).
- 9. Análisis temporal de tendencia mensual, comparación entre años, horas y días de mayor demanda, y evolución del canal web.
- 10. Generación de visualizaciones mediante la librería matplotlib, con título y etiquetas en cada gráfica.
- 11. Interpretación de resultados conforme al esquema de cuatro preguntas: qué se observa, qué significa, posible causa y decisión posible.

5. Análisis de calidad de datos

El dataset limpio no presenta duplicados exactos ni identificadores de venta (id_venta) repetidos, y todos los registros cuentan con id_pedido y fecha_pedido válidos. La cobertura temporal se extiende del 3 de enero de 2025 al 19 de agosto de 2026, sin vacíos relevantes en el periodo.

En cuanto a valores nulos, las columnas con mayor proporción de ausencias son fecha_reservacion y estado_reservacion (75.73%), id_mesa, ubicacion_mesa y tipo_mesa (48.53%), calificacion_servicio (30.55%) y tiempo_entrega_min (15.77%). Estos nulos no deben interpretarse como errores: corresponden a reglas de negocio legítimas del modelo de datos — por ejemplo, un pedido "para llevar" no tiene mesa asignada, un pedido sin reservación no cuenta con fecha ni estado de reservación, y un pedido que no ha sido entregado no puede tener calificación de servicio ni tiempo de entrega.

Respecto a los datos atípicos, se aplicó el método del rango intercuartílico (IQR) sobre las variables numéricas principales. Se identificaron 156 valores atípicos en precio_unitario, 94 en subtotal_linea y 31 en subtotal_pedido, impuestos y total_pedido (estos últimos tres comparten los mismos pedidos, ya que se derivan aritméticamente unos de otros). No se detectaron atípicos en cantidad, tiempo_entrega_min ni calificacion_servicio. Es importante señalar que estos valores no deben considerarse automáticamente errores: dado que el precio_unitario se genera dentro de rangos específicos por categoría (por ejemplo, Alimentos entre \$45.00 y \$95.00), los pedidos con varias líneas de productos de categorías con precios altos pueden alcanzar montos elevados de forma legítima.

Tabla 2. Resumen de calidad de datos

Criterio	Resultado	Interpretación
Valores nulos	Máximo 75.73% en fecha_reservacion / estado_reservacion	Corresponden a reglas de negocio (pedidos sin reservación o sin mesa), no a errores.

Criterio	Resultado	Interpretación
Duplicados	0 duplicados exactos; 0 id_venta repetidos	El dataset limpio no presenta problemas de doble captura.
Datos atípicos (IQR)	156 en precio_unitario; 94 en subtotal_linea; 31 en subtotal_pedido/impuestos/total_pedido	Consistentes con los rangos de precio por categoría; no se consideran errores sin evidencia adicional.
Consistencia	subtotal_linea = cantidad × precio_unitario en el 100% de los registros analizados	Las fórmulas derivadas del pedido son coherentes en la muestra revisada.
Integridad	Todo registro cuenta con id_venta, id_pedido y fecha_pedido	No se identificaron registros incompletos en los campos obligatorios.
Cobertura temporal	03-ene-2025 a 19-ago-2026 (≈20 meses)	El año 2026 está incompleto (hasta agosto), lo que debe considerarse en comparaciones anuales.

6. Análisis univariado

En esta sección se presentan los resultados del análisis individual de las principales variables numéricas y categóricas del dataset.

6.1 Variables numéricas

Las variables cantidad, precio_unitario y subtotal_linea se analizaron a nivel de línea de producto (utilizando df), mientras que subtotal_pedido, impuestos, total_pedido, tiempo_entrega_min y calificacion_servicio se analizaron a nivel de pedido (utilizando pedidos_df, con un registro por id_pedido).

Tabla 3. Medidas descriptivas — variables por línea de producto

Variable	Mediana	Mediana	Moda	Mín.	Máx.	Var.	D. estándar	P25	P50	P75	P90
cantidad	2.01	2.00	2.00	1.00	3.00	0.66	0.81	1.00	2.00	3.00	3.00
precio_unitario	45.20	42.31	35.96	20.03	94.99	247.56	15.73	33.63	42.31	53.27	64.94
subtotal_linea	90.85	81.82	39.64	20.07	284.97	2505.84	50.06	51.74	81.82	117.05	160.61

Tabla 4. Medidas descriptivas — variables por pedido

Variable	Media	Mediana	Moda	Mín.	Máx.	Var.	D. estándar	P25	P50	P75	P90
subtotal_pedido	227.37	215.38	154.90	21.40	671.39	16447.02	128.25	122.26	215.38	310.00	398.28
impuestos	36.38	34.46	4.64	3.42	107.42	421.05	20.52	19.56	34.46	49.60	63.72
total_pedido	263.75	249.84	179.68	24.82	778.81	22131.13	148.77	141.82	249.84	359.60	462.00
tiempo_entrega_min	26.60	27.00	9.00	8.00	45.00	123.97	11.13	17.00	27.00	37.00	42.00
calificacion_servicio	4.08	4.00	5.00	1.00	5.00	1.18	1.09	4.00	4.00	5.00	5.00

7. Interpretación de media, mediana y moda

Media frente a mediana

En total_pedido, la media (263.75) es ligeramente superior a la mediana (249.84), lo que sugiere una distribución levemente asimétrica hacia la derecha: existen pedidos de monto elevado (hasta 778.81) que desplazan el promedio hacia arriba sin representar el comportamiento típico de la mayoría de los pedidos, cuyo valor central se ubica más cerca de los 250 MXN. Un patrón similar se observa en precio_unitario (media 45.20 frente a mediana 42.31) y en subtotal_linea (media 90.85 frente a mediana 81.82). En cambio, en tiempo_entrega_min la media (26.60) y la mediana (27.00) son prácticamente iguales, lo que indica una distribución más simétrica y sin una influencia importante de valores extremos.

Moda

La cantidad de unidades por línea tiene como valor más frecuente 2 unidades, coherente con el rango de generación (1 a 3). La calificación de servicio más frecuente es 5 estrellas, lo que confirma la concentración de calificaciones altas observada en la distribución. En las variables categóricas, la categoría de producto más frecuente es Repostería (17.37% de las líneas), el producto más frecuente es Frappé de café, el canal más frecuente es Página web (56.47% de las líneas) y el estado de pedido más frecuente es entregado (69.45%).

Varianza y desviación estándar


Las variables monetarias muestran una dispersión considerable: total_pedido presenta una desviación estándar de 148.77 sobre una media de 263.75, lo que indica que el monto de los pedidos varía de forma importante entre clientes y ocasiones de compra. En contraste, cantidad (desviación estándar 0.81) y calificacion_servicio (desviación estándar 1.09) muestran una dispersión baja, consistente con su rango acotado de valores posibles.

Percentiles

El percentil 75 de total_pedido (359.60) indica que el 75% de los pedidos no supera este monto, mientras que el percentil 90 (462.00) muestra que solamente el 10% de los pedidos alcanza montos superiores a esta cifra. Esto confirma que los pedidos de alto valor, aunque existen, son relativamente poco frecuentes dentro del conjunto de datos.

8. Distribuciones

Figura 1. Distribución del ticket total por pedido




Qué se observa: La mayoría de los pedidos se concentra entre aproximadamente 100 y 400 MXN, con una media de 263.75 MXN, una mediana de 249.84 MXN y un máximo de 778.81 MXN.

Qué significa: El ticket promedio de Café Cereza se ubica en un rango medio-bajo, y los pedidos de montos muy altos son poco frecuentes dentro del total de transacciones.

Posible causa: Una posible explicación podría ser que los clientes suelen realizar pedidos de pocos productos o de consumo individual, en lugar de compras grupales de gran volumen.

Decisión posible: Café Cereza podría diseñar combos o promociones de venta adicional (upselling) orientados a incrementar el valor promedio de cada pedido.

Figura 2. Distribución del tiempo de entrega




Qué se observa: Los tiempos de entrega, disponibles únicamente para pedidos en estado "entregado" o "listo" (1,270 pedidos), se distribuyen entre 8 y 45 minutos, con una media de 26.60 minutos y una mediana de 27 minutos.

Qué significa: El servicio presenta tiempos de entrega variados a lo largo de todo el rango observado, sin una concentración marcada en un intervalo específico.

Posible causa: Este comportamiento podría estar relacionado con diferencias en la cantidad de productos por pedido, la complejidad de su preparación o la carga de trabajo en distintos horarios.

Decisión posible: Café Cereza podría identificar los pedidos con mayores tiempos de entrega y revisar sus procesos de preparación para reducir la variabilidad del servicio.

Figura 3. Distribución de calificaciones del servicio



Qué se observa: Las calificaciones, disponibles solo para pedidos entregados (2,607 pedidos), muestran una fuerte concentración en 5 estrellas (483 pedidos) y 4 estrellas (307 pedidos), mientras que las calificaciones bajas (1 y 2 estrellas) suman 109 pedidos.

Qué significa: La percepción del servicio es mayoritariamente positiva entre los clientes que completaron su pedido y lo calificaron.

Posible causa: Una posible explicación podría ser una atención y experiencia de compra generalmente satisfactoria; también debe considerarse que la generación de estos datos favorece deliberadamente las calificaciones altas.

Decisión posible: Café Cereza podría mantener las prácticas de servicio actuales e investigar específicamente las causas de las calificaciones de 1 y 2 estrellas para atender casos puntuales de insatisfacción.

9. Análisis de frecuencias

Se analizaron las principales variables categóricas del dataset a nivel de línea de producto (categoria_producto, producto) y a nivel de pedido (canal_venta, tipo_cliente, tipo_pedido, metodo_pago, estado_pedido), identificando la categoría más frecuente (moda) de cada una.

Tabla 5. Frecuencia de la categoría más común por variable


Variable	Categorías distintas	Moda	Frecuencia	%
categoria_producto	6	Repostería	652	17.37%
producto	29	Frappé de café	179	4.77%
canal_venta	3	Página web	2,120 líneas / 837 pedidos	56.47% (líneas)
tipo_cliente	4	Frecuente	2,319 líneas / 921 pedidos	61.77% (líneas)
tipo_pedido	2	en el lugar	1,932 líneas / 761 pedidos	51.47% (líneas)
metodo_pago	4	pago en línea	1,838 líneas / 728 pedidos	48.96% (líneas)
estado_pedido	4	entregado	2,607 líneas / 1,049 pedidos	69.45% (líneas)

La distribución de categoria_producto es relativamente equilibrada: Repostería (17.37%), Café caliente (17.13%) y Café frío (17.02%) encabezan la lista, seguidas de Alimentos (16.78%), Bebidas frías (15.88%) y Bebidas calientes (15.82%), sin que ninguna categoría concentre una proporción desproporcionada de las líneas de producto. En canal_venta, la Página web concentra 837 de los 1,500 pedidos (55.80%), frente a 344 pedidos en Presencial (mostrador) (22.93%) y 319 en Presencial (mesero) (21.27%). En tipo_cliente, los clientes clasificados como Frecuente (921 pedidos, 61.40%) y VIP (514 pedidos, 34.27%) concentran en conjunto el 95.67% de los pedidos, mientras que Recurrente (59 pedidos) y Nuevo (6 pedidos) representan una proporción marginal.

10. Análisis bivariado

En esta sección se presentan las relaciones entre pares de variables generadas en el notebook, con su interpretación correspondiente.

Figura 4. Unidades vendidas por categoría




Qué se observa: Repostería lidera con 1,321 unidades vendidas, seguida de Café caliente (1,282), Alimentos (1,271), Café frío (1,269), Bebidas frías (1,220) y Bebidas calientes (1,194).

Qué significa: Las ventas en unidades se mantienen relativamente equilibradas entre las seis categorías del catálogo, sin una categoría que domine claramente sobre las demás.

Posible causa: Una posible explicación es que los clientes de Café Cereza distribuyen su interés entre distintos tipos de producto, en lugar de concentrarse en una sola categoría.

Decisión posible: Café Cereza podría mantener un inventario equilibrado entre categorías y reforzar promociones puntuales en Bebidas calientes y Bebidas frías, las de menor volumen relativo.

Figura 5. Top 10 productos más vendidos




Qué se observa: El Frappé de café encabeza el ranking con 352 unidades, seguido de Chocolate caliente (346), Sandwich club (345), Bagel con queso crema (323) y Panini de jamón y queso (311).

Qué significa: Las preferencias de los clientes se distribuyen entre bebidas y alimentos, con diferencias relativamente pequeñas entre los diez productos principales.

Posible causa: Una posible explicación es la popularidad y demanda constante de estos productos entre la comunidad universitaria a la que atiende la cafetería.

Decisión posible: Café Cereza podría asegurar la disponibilidad en inventario de estos productos y utilizarlos como base de combos junto con productos de menor rotación.

Figura 6. Ingresos por categoría




Qué se observa: Alimentos genera los mayores ingresos (88,484.63 MXN), seguida de Café frío (64,312.74 MXN) y Repostería (56,620.12 MXN), mientras que Bebidas frías registra el menor monto (36,496.61 MXN).

Qué significa: Una categoría puede generar mayores ingresos sin ser la que más unidades vende, ya que el aporte económico depende también del precio unitario de sus productos.

Posible causa: El rango de precio unitario de Alimentos (\$45.00–\$95.00) es considerablemente más alto que el de las demás categorías, lo que explica su mayor participación en ingresos aunque no lidere en unidades.

Decisión posible: Café Cereza podría fortalecer la oferta de Alimentos y Café frío por su aporte económico, y evaluar estrategias de precio o combos para las categorías de menor ingreso.

Figura 7. Ticket promedio por canal de venta




Qué se observa: La Página web presenta el ticket promedio más alto (269.34 MXN), seguida de Presencial (mesero) (262.39 MXN) y Presencial (mostrador) (251.43 MXN).

Qué significa: Los pedidos realizados a través del canal digital tienden a tener, en promedio, un valor ligeramente superior a los realizados de forma presencial.

Posible causa: Una posible explicación es que el catálogo digital facilita visualizar más opciones del menú y agregar varios productos en un mismo pedido en línea.

Decisión posible: Café Cereza podría fortalecer el canal web mediante recomendaciones de productos y combos que aprovechen este comportamiento.

Figura 8. Número de pedidos por tipo de cliente




Qué se observa: Los clientes Frecuentes concentran la mayor cantidad de pedidos (921), seguidos de los VIP (514); los clientes Recurrentes (59) y Nuevos (6) representan una proporción mucho menor.

Qué significa: La demanda del negocio depende en gran medida de un grupo relativamente reducido de clientes con una relación ya establecida con Café Cereza.

Posible causa: Una posible explicación es la fidelización de los clientes actuales, favorecida por la cercanía del negocio con la comunidad universitaria.

Decisión posible: Café Cereza podría mantener estrategias de fidelización para clientes Frecuentes y VIP, y desarrollar acciones específicas para atraer y retener clientes Nuevos.

Figura 9. Tiempo promedio de entrega por canal




Qué se observa: Los tiempos promedio de entrega son muy similares entre canales: Página web (26.78 min), Presencial (mesero) (26.54 min) y Presencial (mostrador) (26.24 min).

Qué significa: El canal por el que se realiza el pedido no genera diferencias relevantes en el tiempo de entrega observado.

Posible causa: Esto es consistente con el hecho de que, en la simulación, el tiempo de entrega no depende del canal de venta sino que se genera de forma independiente para todos los pedidos entregados o listos.

Decisión posible: Café Cereza podría enfocar sus esfuerzos de mejora del tiempo de entrega en el proceso de preparación en general, en lugar de en un canal específico.

Figura 10. Reservaciones por estado



Qué se observa: De los 368 pedidos con reservación asociada, 270 fueron completadas, 39 canceladas, 35 registraron no_show y 24 permanecen pendientes.

Qué significa: La mayoría de las reservaciones (73.37%) se concreta de manera satisfactoria, aunque existe una proporción relevante de cancelaciones y no asistencias.


Posible causa: Una posible explicación es que la mayoría de los clientes que reservan mesa tienen una intención clara de asistir, aunque un grupo menor puede cambiar de planes sin cancelar formalmente.

Decisión posible: Café Cereza podría implementar recordatorios previos a la reservación para reducir la tasa de cancelaciones y de no_show.

11. Análisis multivariado

En esta sección se analizan de manera conjunta tres o más variables, combinando dimensiones de tiempo, canal, categoría y tipo de cliente.

Figura 11. Ventas mensuales por canal




Qué se observa: Los ingresos de los canales presenciales se mantienen relativamente estables mes a mes, mientras que los ingresos del canal Página web crecen de forma sostenida desde su aparición en julio de 2025, alcanzando 45,886.61 MXN en julio de 2026 y 43,650.23 MXN en agosto de 2026 (mes incompleto).

Qué significa: El crecimiento de los ingresos totales de Café Cereza está impulsado principalmente por la expansión del canal digital, más que por un incremento generalizado en los canales presenciales.

Posible causa: Una posible explicación podría ser una mayor adopción del canal digital por parte de los clientes conforme transcurre el tiempo desde su lanzamiento.

Decisión posible: Café Cereza podría fortalecer su infraestructura y operación de pedidos web, asegurando capacidad suficiente de preparación y entrega ante el crecimiento sostenido de este canal.

Figura 12. Unidades por categoría y canal




Qué se observa: En todas las categorías, la Página web concentra la mayor cantidad de unidades vendidas, destacando Repostería (763 unidades), Alimentos (737) y Café caliente (726), muy por encima de los canales presenciales.

Qué significa: El canal digital no solo genera más pedidos en total, sino que también domina la venta de unidades en cada una de las seis categorías del catálogo, sin concentrarse en un tipo particular de producto.

Posible causa: Esto es consistente con la mayor participación general de la Página web en el número de pedidos (55.80%), más que con una preferencia especial por alguna categoría en ese canal.

Decisión posible: Café Cereza podría asegurar niveles de inventario suficientes en todas las categorías para sostener la demanda proveniente del canal web.

Figura 13. Ticket promedio por canal y tipo de cliente



Qué se observa: El ticket promedio varía según la combinación de canal y tipo de cliente: los clientes Recurrentes alcanzan su ticket más alto en Página web (293.60 MXN), mientras que los clientes Nuevos presentan su ticket más alto en Presencial (mesero) (308.75 MXN), aunque con una base de solo 6 pedidos.

Qué significa: El comportamiento de gasto no es uniforme entre segmentos de cliente y canal; algunos segmentos con pocos pedidos (como Nuevo) muestran variaciones que deben interpretarse con cautela por el tamaño reducido de la muestra.

Posible causa: Una posible explicación es que los clientes con mayor antigüedad o relación con la cafetería (Frecuente, VIP, Recurrente) desarrollan patrones de compra más estables por canal, mientras que los clientes Nuevos aún no consolidan un patrón definido.


Decisión posible: Café Cereza podría diseñar estrategias de bienvenida para clientes Nuevos que fomenten pedidos de mayor valor desde las primeras compras.

12. Análisis temporal

El análisis temporal constituye uno de los ejes principales de este reporte, ya que permite identificar la evolución de la demanda y los periodos de mayor actividad de Café Cereza.

12.1 Tendencia mensual

Figura 14. Tendencia mensual de ingresos



Qué se observa: Los ingresos mensuales muestran una tendencia general de crecimiento, pasando de 214.76 MXN en enero de 2025 a 60,914.98 MXN en julio de 2026 (el mes con mayores ingresos de todo el periodo), con una ligera disminución a 60,051.96 MXN en agosto de 2026 (mes incompleto).


Qué significa: El negocio simulado muestra una expansión sostenida de sus ingresos a lo largo del periodo analizado, sin retrocesos abruptos entre meses consecutivos.

Posible causa: Una posible explicación es el efecto combinado del aumento progresivo en el número de pedidos y el crecimiento de la participación del canal web, ambos crecientes a lo largo del periodo.

Decisión posible: Café Cereza podría anticipar necesidades de inventario y personal conforme continúe esta tendencia de crecimiento, evitando desabastos en los meses de mayor demanda.

12.2 Comparación entre años

Figura 15. Comparación mensual 2025 vs 2026



Qué se observa: Al comparar únicamente los meses de enero a agosto —periodo comparable entre ambos años—, los ingresos pasan de 43,260.78 MXN en 2025 a 289,720.06 MXN en 2026, un incremento de 569.71% en ese lapso.

Qué significa: El crecimiento del negocio simulado entre ambos años es considerable incluso al restringir la comparación a meses equivalentes, lo que confirma que la tendencia no es un artefacto de comparar periodos de distinta duración.


Posible causa: Una posible explicación es el crecimiento acumulado en el número de pedidos y la mayor consolidación del canal web durante 2026.

Decisión posible: Café Cereza podría analizar qué factores impulsaron este crecimiento (adopción del canal digital, fidelización de clientes) para mantenerlos y reforzarlos en los próximos meses.

Es importante señalar que 2026 solo contiene información hasta el 19 de agosto, por lo que no debe compararse el total del año 2026 contra el total completo de 2025; los meses de septiembre a diciembre de 2026 aparecen en cero en la tabla del notebook porque aún no existen registros para ese periodo, no porque las ventas hayan sido nulas.

12.3 Horas de mayor demanda

Figura 16. Pedidos por hora del día



Qué se observa: Los pedidos se distribuyen de forma relativamente uniforme entre las 7:00 y las 20:00 horas (entre 90 y 126 pedidos por hora), con la mayor concentración a las 11:00 horas (126 pedidos), seguida de las 13:00 (122) y las 18:00 (116).


Qué significa: Aunque existen ligeros picos de demanda, no se observa una concentración extrema en un horario específico dentro del rango de operación.

Posible causa: Una posible explicación podría estar relacionada con horarios habituales de desayuno, comida y salida de actividades académicas; sin embargo, dado que la simulación genera la hora de cada pedido de forma uniforme entre las 7 y las 20 horas, estas variaciones también son compatibles con el azar propio del muestreo.

Decisión posible: Café Cereza podría reforzar personal y preparación de productos alrededor de las 11:00 y 13:00 horas como medida preventiva ante posibles picos de demanda real.

12.4 Días de mayor demanda

Figura 17. Pedidos por día de la semana



Qué se observa: Los pedidos se mantienen relativamente equilibrados durante la semana, con el martes registrando la mayor cantidad (236 pedidos) y el domingo la menor (194 pedidos).


Qué significa: No existe un día que concentre de forma desproporcionada la demanda; las diferencias entre días son moderadas.

Posible causa: Una posible explicación podría estar relacionada con la dinámica de actividades universitarias entre semana; no obstante, dado que la fecha de cada pedido se genera de forma aleatoria uniforme en la simulación, esta variación también es coherente con el azar del muestreo.

Decisión posible: Café Cereza podría ajustar personal e inventario de forma moderada entre semana y fin de semana, sin requerir cambios drásticos por día.

12.5 Canal web

Figura 18. Participación mensual del canal web




Qué se observa: La participación del canal web sobre el total de pedidos comienza en 11.76% en julio de 2025 (mes de su lanzamiento) y crece hasta alcanzar su punto más alto en julio de 2026 con 71.81%, situándose en 69.26% en agosto de 2026.

Qué significa: La página web pasó de ser un canal marginal a convertirse en el canal predominante de Café Cereza en poco más de un año.

Posible causa: Este comportamiento corresponde a una regla explícita de la simulación (documentada en Documento_Reglas_Simulacion.pdf): a partir del 1 de julio de 2025, el peso asignado al canal web crece de forma programada con el tiempo transcurrido desde el lanzamiento, hasta un máximo aproximado de 70%. Por lo tanto, esta tendencia no debe interpretarse como un hallazgo espontáneo del negocio, sino como un patrón diseñado deliberadamente en la generación de los datos, aunque coherente con el objetivo del proyecto de evaluar la adopción del canal digital.

Decisión posible: Café Cereza podría utilizar esta proyección como referencia de planeación para la capacidad operativa del canal digital conforme el negocio inicie operaciones reales.

Figura 19. Pedidos antes y después del lanzamiento web



Qué se observa: Después del lanzamiento de la página web (1 de julio de 2025) se registraron 837 pedidos por este canal, frente a 302 en mostrador y 272 con mesero en el mismo periodo; antes del lanzamiento, todos los pedidos se distribuían entre los dos canales presenciales (47 con mesero y 42 en mostrador).

Qué significa: El canal web adquirió una participación relevante dentro de las ventas totales una vez disponible, sin que ello implique una disminución absoluta de los pedidos presenciales.

Posible causa: Una posible explicación es la facilidad de realizar pedidos de manera digital, sin los tiempos de espera asociados al canal presencial.


Decisión posible: Café Cereza podría continuar impulsando el canal web como complemento de la atención presencial, en lugar de sustituto.

Nota metodológica: los periodos "antes" y "después" del lanzamiento web comparados en la Figura 19 tienen duración distinta (6 meses frente a poco más de 13 meses), por lo que el incremento total de pedidos no debe atribuirse únicamente al lanzamiento de la página web.

13. Correlación entre variables numéricas

Se calculó la matriz de correlación de Pearson entre las principales variables numéricas del dataset. Los resultados deben interpretarse únicamente como asociaciones estadísticas, sin que impliquen una relación de causa y efecto.

Figura 20. Matriz de correlación de variables numéricas



Qué se observa: Existe una correlación positiva moderada-alta entre cantidad y subtotal_linea (0.73), y entre precio_unitario y subtotal_linea (0.63), como es esperable dado que subtotal_linea se calcula directamente a partir de ambas. Las correlaciones entre subtotal_pedido, impuestos y total_pedido son perfectas (1.00) por tratarse de variables derivadas entre sí. En contraste, tiempo_entrega_min y calificacion_servicio muestran correlaciones cercanas a cero con las demás variables (entre -0.04 y 0.01).

Qué significa: El monto de un pedido está fuertemente determinado por la cantidad y el precio de los productos que lo componen, lo cual es consistente con la fórmula de cálculo del dataset. En cambio, el tiempo de entrega y la calificación del servicio no muestran una relación lineal relevante con el monto del pedido.

Posible causa: La ausencia de correlación entre tiempo_entrega_min o calificacion_servicio y las variables monetarias es coherente con la forma en que estas variables se generan en la simulación, de manera independiente del monto del pedido.

Decisión posible: Café Cereza podría descartar, con la evidencia disponible, que un mayor gasto esté asociado a mejores o peores tiempos de entrega o calificaciones, y enfocar la mejora del servicio en factores operativos distintos al monto de la compra.

14. Hallazgos principales

- El ticket promedio del canal Página web (\$269.34) es el más alto de los tres canales de venta, 7.13% superior al de Presencial (mostrador) (\$251.43), lo que indica que los pedidos digitales tienden a tener mayor valor.
- Los ingresos totales de enero a agosto crecieron 569.71% entre 2025 (\$43,260.78) y 2026 (\$289,720.06), lo que confirma una expansión sostenida del negocio simulado incluso al comparar periodos equivalentes.
- La participación del canal web sobre el total de pedidos pasó de 11.76% en julio de 2025 (mes de lanzamiento) a 71.81% en julio de 2026, lo que evidencia una adopción creciente del canal digital, en parte inducida por el diseño de la simulación.
- El Frappé de café es el producto más vendido con 352 unidades, mientras que Repostería es la categoría con más unidades (1,321), aunque Alimentos genera el mayor ingreso (\$88,484.63) debido a su rango de precio más alto.
- Los clientes clasificados como Frecuente y VIP concentran el 95.67% de los 1,500 pedidos (921 y 514 pedidos, respectivamente), lo que indica una fuerte dependencia de clientes con relación previa establecida.
- La hora con mayor número de pedidos es las 11:00 (126 pedidos) y el día con mayor actividad es el martes (236 pedidos), aunque ambas distribuciones se mantienen relativamente equilibradas a lo largo del horario y de la semana.
- El 79.61% de las calificaciones de servicio corresponde a 4 o 5 estrellas (790 de 2,607 pedidos calificados con 5 y 4 estrellas: 483 + 307), lo que refleja una percepción mayoritariamente positiva del servicio entre los clientes que calificaron su pedido.
- La tasa de cancelación de pedidos es de 5.33% (80 de 1,500 pedidos) y la tasa de no_show en reservaciones es de 9.51% (35 de 368 reservaciones), indicadores relevantes para la gestión operativa de la cafetería.
- El tiempo de entrega promedio es de 26.60 minutos, con un comportamiento muy similar entre los tres canales de venta (diferencia máxima de 0.54 minutos), lo que indica que el canal no afecta el tiempo de servicio.
- El 24.53% de los pedidos "en el lugar" incluye una reservación previa (368 de 1,500 pedidos totales), de los cuales el 73.37% se completó satisfactoriamente.

- Existe una correlación fuerte entre cantidad y subtotal_linea (0.73), consistente con la fórmula de cálculo del dataset, mientras que el tiempo de entrega y la calificación de servicio no muestran correlación relevante con ninguna variable monetaria (valores entre -0.04 y 0.01).
- La distribución de unidades vendidas entre las seis categorías de producto es relativamente equilibrada (entre 1,194 y 1,321 unidades), lo que sugiere que los clientes de Café Cereza no concentran su consumo en un solo tipo de producto.

15. Tabla de hallazgos

Tabla 6. Hallazgos principales y evidencia

N.º	Hallazgo	Evidencia	Implicación para el negocio
1	Ticket promedio más alto en Página web (\$269.34)	Figura 7	El canal digital genera pedidos de mayor valor; conviene reforzarlo comercialmente.
2	Crecimiento de 569.71% en ingresos ene-ago 2025→2026	Figura 15	El negocio muestra una tendencia de expansión sostenida en periodos comparables.
3	Participación web de 11.76% a 71.81% (jul-2025 a jul-2026)	Figura 18	Planeación de capacidad operativa para el canal digital.
4	Frappé de café: producto más vendido (352 unidades)	Figura 5	Asegurar disponibilidad e inventario de productos de alta rotación.
5	Alimentos: mayor ingreso por categoría (\$88,484.63)	Figura 6	Priorizar la categoría con mayor aporte económico en estrategia comercial.
6	95.67% de pedidos de clientes Frecuente/VIP	Figura 8	Alta dependencia de clientes fidelizados; oportunidad de atraer clientes nuevos.
7	Pico de demanda: 11:00 h y martes	Figuras 16 y 17	Planeación de personal en horarios y días de mayor actividad.
8	79.61% de calificaciones de 4 y 5 estrellas	Figura 3	Percepción de servicio mayoritariamente positiva.

N.º	Hallazgo	Evidencia	Implicación para el negocio
9	Cancelación de pedidos: 5.33%; no_show en reservas: 9.51%	Hallazgos automáticos; Figura 10	Áreas de mejora en confirmación de pedidos y reservaciones.
10	Tiempo de entrega promedio de 26.60 min, similar entre canales	Figuras 2 y 9	El canal no es un factor relevante para mejorar tiempos de servicio.
11	24.53% de pedidos en el lugar incluye reservación previa	Sección 5.1 del notebook	El sistema de reservaciones tiene una adopción parcial entre los pedidos presenciales.
12	Correlación fuerte cantidad–subtotal_linea (0.73); nula con tiempo/calificación	Figura 20	El monto del pedido no está asociado, en los datos disponibles, a mejor o peor servicio.

16. Preguntas de negocio y resultados

A continuación se relacionan las ocho preguntas de negocio originales, formuladas en la sección 1.4 de CAFÉ CEREZA - Etapa1.pdf, con los resultados obtenidos en este EDA.

Tabla 7. Preguntas de negocio y resultados obtenidos

Pregunta de negocio	Análisis realizado	Resultado obtenido	Evidencia	¿Respondida?
¿Qué días y horarios presentan la mayor demanda de reservaciones y pedidos anticipados?	Pedidos por hora y por día de la semana	Mayor demanda a las 11:00 h y los martes, con distribución relativamente equilibrada en el resto del horario/semana	Figuras 16 y 17	Sí
¿Cuál es el tiempo de espera promedio que los clientes están dispuestos a tolerar antes de optar por otra opción cercana?	No aplica: el dataset no registra clientes que abandonaron la intención de compra ni su tolerancia de espera	No determinado a partir de los archivos proporcionados	—	No
¿Qué productos del menú generan mayor frecuencia de pedido anticipado en comparación con el	Unidades vendidas por producto y por canal	El canal Página web concentra la mayor cantidad de unidades en todas las categorías, pero el dataset no distingue	Figuras 5 y 12	Parcialmente

Pregunta de negocio	Análisis realizado	Resultado obtenido	Evidencia	¿Respondida?
consumo directo en sitio?		explícitamente "pedido anticipado" de "consumo directo" dentro de cada canal		
¿Cómo se comporta la tasa de cancelación o "no asistencia" en las reservaciones de mesa?	Distribución de estado_reservacion	73.37% completadas, 10.60% canceladas, 9.51% no_show, 6.52% pendientes (sobre 368 reservaciones)	Figura 10	Sí
¿Qué combinación de productos (combos estudiantiles, desayunos, paquetes) maximiza el ticket promedio de los pedidos anticipados?	No aplica: el dataset no contiene una variable de combos ni de promociones/descuentos	No determinado a partir de los archivos proporcionados	—	No
¿Cuál es el tiempo promedio que transcurre entre que un cliente realiza su reservación o pedido y llega a recoger su orden o su mesa?	No aplica: el dataset registra tiempo_entrega_min (preparación) pero no un tiempo de llegada del cliente tras reservar o pedir	No determinado a partir de los archivos proporcionados	—	No
¿Qué canal (página web, WhatsApp, redes sociales) genera más reservaciones efectivamente concretadas?	Estado de reservación y canal de venta	El dataset registra canal_venta (Página web, Presencial mostrador, Presencial mesero) y no distingue WhatsApp ni redes sociales como canal independiente; la Página web concentra el mayor número de pedidos generales	Figura 10; Tabla 5	Parcialmente
¿Cómo impacta contar con un sistema de reservaciones en la fidelización y frecuencia de visita de la comunidad estudiantil?	Distribución de tipo_cliente y de reservaciones	Los clientes Frecuente y VIP concentran el 95.67% de los pedidos, pero el dataset no permite aislar el efecto causal de las reservaciones sobre la fidelización	Figura 8	Parcialmente

17. Principales patrones identificados

Productos

Repostería destaca como la categoría con más unidades vendidas y el Frappé de café como el producto individual más vendido; sin embargo, Alimentos genera el mayor ingreso económico gracias a su precio unitario más alto, lo que muestra que volumen e ingreso no siempre coinciden en la misma categoría.

Clientes

La demanda se concentra fuertemente en clientes Frecuente y VIP (95.67% de los pedidos), mientras que los segmentos Nuevo y Recurrente representan una proporción marginal, lo que refleja una base de clientes consolidada dentro de la simulación.

Canales

La Página web es el canal dominante, tanto en número de pedidos (55.80%) como en unidades vendidas por categoría y en ticket promedio, con una participación creciente a lo largo del periodo analizado.

Tiempo

La mayor demanda se concentra alrededor de las 11:00 y 13:00 horas y los martes, aunque las diferencias entre horas y días son moderadas. A nivel mensual, existe una tendencia de crecimiento sostenido en ingresos, más pronunciada en 2026.

Servicio

Los tiempos de entrega (promedio 26.60 minutos) son consistentes entre canales, y las calificaciones de servicio muestran una concentración mayoritaria en 4 y 5 estrellas.

Reservaciones

Del total de pedidos, 24.53% incluye una reservación previa, de las cuales el 73.37% se completa satisfactoriamente; las cancelaciones (10.60%) y los casos de no_show (9.51%) representan áreas de atención operativa.

18. Limitaciones del análisis

- Los datos analizados son enteramente simulados, generados mediante reglas y probabilidades programadas (documentadas en Documento_Reglas_Simulacion.pdf); no representan ventas reales de Café Cereza, ya que el negocio se encuentra en una etapa previa a su operación.
- El año 2026 solo contiene información hasta el 19 de agosto, por lo que no debe compararse como un año completo frente a 2025; las comparaciones anuales de este documento se restringieron a los meses de enero a agosto de ambos años.
- Las correlaciones reportadas en la sección 13 representan asociaciones estadísticas y no relaciones de causa y efecto; no debe inferirse causalidad a partir de ellas.
- Algunos patrones observados, como el crecimiento de la participación del canal web, corresponden a reglas explícitamente programadas en el generador de datos y no a hallazgos espontáneos del comportamiento de un negocio real; esto se señaló específicamente en la interpretación de la Figura 18.

- El dataset representa líneas de producto dentro de pedidos, por lo que fue necesario controlar las métricas a nivel de pedido (ingresos, ticket promedio, tiempo de entrega y calificación) mediante la tabla auxiliar pedidos_df, para evitar duplicaciones.
- No se dispone de información sobre utilidad, costo de los productos, dispositivo desde el cual se realizó el pedido, ni campañas publicitarias asociadas; por lo tanto, no se presenta ningún análisis relacionado con estas variables.
- Tampoco se dispone de variables de edad, género del cliente, promociones, descuentos ni empleado responsable de la venta, conforme a lo documentado en Documento_Reglas_Simulacion.pdf; las preguntas de negocio que dependían de esta información se marcaron como no respondidas.
- El canal de venta registrado (Página web, Presencial mostrador, Presencial mesero) no distingue WhatsApp ni redes sociales como canales independientes, por lo que las preguntas de negocio relacionadas con estos medios solo pudieron responderse de forma parcial.

19. Recomendaciones preliminares

Las siguientes recomendaciones se derivan exclusivamente de los hallazgos de este EDA y deben considerarse preliminares; podrán complementarse posteriormente con el cálculo de KPIs y la construcción de un dashboard administrativo.

- Diseñar combos o estrategias de venta adicional que incrementen el ticket promedio, dado que la mayoría de los pedidos se concentra en montos entre 100 y 400 MXN.
- Priorizar la disponibilidad de inventario de los productos y categorías de mayor rotación (Frappé de café, Repostería) y de mayor ingreso (Alimentos, Café frío).
- Reforzar personal y preparación durante las horas de mayor demanda (11:00 y 13:00 horas) y los días de mayor actividad (martes), sin descuidar el resto del horario, dado el comportamiento relativamente equilibrado observado.
- Continuar fortaleciendo el canal web mediante mejoras en la experiencia de compra, dado su ticket promedio más alto y su creciente participación en el total de pedidos.
- Diseñar estrategias específicas para atraer y fidelizar clientes Nuevos y Recurrentes, dado que la demanda actual depende en gran medida de clientes Frecuente y VIP.
- Implementar recordatorios previos a la fecha de reservación para reducir las tasas de cancelación (10.60%) y no_show (9.51%) observadas.
- Mantener las prácticas actuales de atención al cliente, dado el alto porcentaje de calificaciones de 4 y 5 estrellas, e investigar puntualmente las causas de las calificaciones bajas.

20. Conclusión

El presente Análisis Exploratorio de Datos permitió examinar de manera sistemática el comportamiento de las ventas, productos, clientes, canales, tiempos de entrega y reservaciones de Café Cereza a partir del dataset dataset_ventas_limpio.csv, compuesto por 3,754 líneas de detalle correspondientes a 1,500 pedidos y 250 clientes, durante el periodo comprendido entre enero de 2025 y agosto de 2026.

Entre los principales resultados destaca una tendencia sostenida de crecimiento en los ingresos, impulsada de forma importante por la creciente adopción del canal Página web, cuya participación pasó de 11.76% a

71.81% entre julio de 2025 y julio de 2026, y que además presenta el ticket promedio más alto de los tres canales analizados. En materia de productos, el Frappé de café y la categoría Repostería concentran la mayor demanda en unidades, mientras que Alimentos genera el mayor ingreso económico. La demanda se concentra en clientes Frecuente y VIP, y presenta picos moderados alrededor de las 11:00 horas y los martes, sin una estacionalidad extrema. El servicio, medido a través del tiempo de entrega y la calificación otorgada por los clientes, muestra un comportamiento consistente entre canales y una percepción mayoritariamente favorable.

De las ocho preguntas de negocio planteadas en la Etapa 1 del proyecto, tres pudieron responderse de manera completa, tres de forma parcial —debido a limitaciones en las variables disponibles del dataset, particularmente en torno a los canales de comunicación (WhatsApp, redes sociales) y a la distinción entre pedido anticipado y consumo directo— y dos no pudieron determinarse con la información proporcionada, al no existir variables relacionadas con tiempos de tolerancia del cliente, combos o tiempos de llegada tras la reservación.

En conjunto, este análisis exploratorio cumple su propósito de transformar los datos simulados de Café Cereza en información comprensible y accionable, sentando las bases metodológicas y de contenido para las siguientes etapas del proyecto: el cálculo de indicadores clave de desempeño (KPIs) y la construcción de un dashboard administrativo que permita a los responsables del negocio dar seguimiento continuo a las métricas aquí identificadas.