

CAFÉ CEREZA

- Proceso ETL y Registro de Transformaciones -



Analítica de Datos para Negocios Digitales

Limpieza, Transformación y Documentación del Proceso ETL

3.1 Introducción

Un proceso ETL (Extracción, Transformación y Carga) es el conjunto de actividades mediante las cuales los datos se obtienen de una fuente original, se perfilan y depuran para corregir errores o inconsistencias, se transforman a una estructura adecuada para el análisis y, finalmente, se cargan en un destino donde pueden explotarse de forma confiable. En un proyecto como el de Café Cereza, este proceso resulta indispensable porque los datos de ventas se generan a partir de múltiples fuentes de captura (pedidos presenciales, pedidos por página web, reservaciones y pagos) y, como ocurre en cualquier sistema real, están expuestos a errores de captura, valores faltantes, formatos inconsistentes y registros duplicados.

La calidad de los datos que alimentan los indicadores clave de desempeño (KPI) y los tableros de control (dashboards) de la cafetería determina directamente la confiabilidad de las decisiones que se tomen a partir de ellos. Si el dataset de ventas contiene duplicados, valores fuera de rango o categorías mal escritas, cualquier KPI calculado sobre él — ticket promedio, ventas por canal, participación del comercio electrónico, calificación de servicio, etc. — quedará distorsionado. Por ello, limpiar y documentar cada transformación aplicada a los datos no es un paso opcional, sino una condición previa para que el análisis posterior sea válido.

Este documento describe, con base en el análisis directo de los archivos entregados, el proceso ETL implementado para el dataset de ventas de Café Cereza: su punto de partida, las transformaciones efectivamente realizadas, los resultados obtenidos y las observaciones técnicas que se desprenden de comparar la salida real del proceso contra un dataset de referencia.

3.2 Objetivo

El objetivo de este documento es transformar y documentar el tratamiento del dataset de ventas de Café Cereza, que contiene errores introducidos deliberadamente, con el fin de obtener información estructurada, coherente y adecuada para su análisis posterior. Para ello es indispensable distinguir con claridad entre tres archivos que cumplen funciones distintas dentro del proyecto:

- Dataset de entrada: `dataset_ventas_sucio.csv`, que contiene los datos con errores introducidos a propósito y constituye el punto de partida del proceso ETL.
- Dataset ideal de referencia o control: `dataset_ventas_limpio.csv`, generado originalmente antes de introducir los errores. Se utiliza únicamente como parámetro de comparación, no como salida del ETL implementado.

- Dataset obtenido realmente después de la transformación: dataset_maestro_limpio.csv, producido por el proceso de limpieza y transformación implementado, y que constituye la salida real que debe evaluarse.

Esta distinción es central en el documento: todas las secciones de validación y comparación evalúan el dataset maestro contra el dataset sucio (para medir el efecto real de las transformaciones) y contra el dataset de referencia (para dimensionar la brecha entre el resultado obtenido y el resultado ideal esperado).

3.3 Fuentes de datos

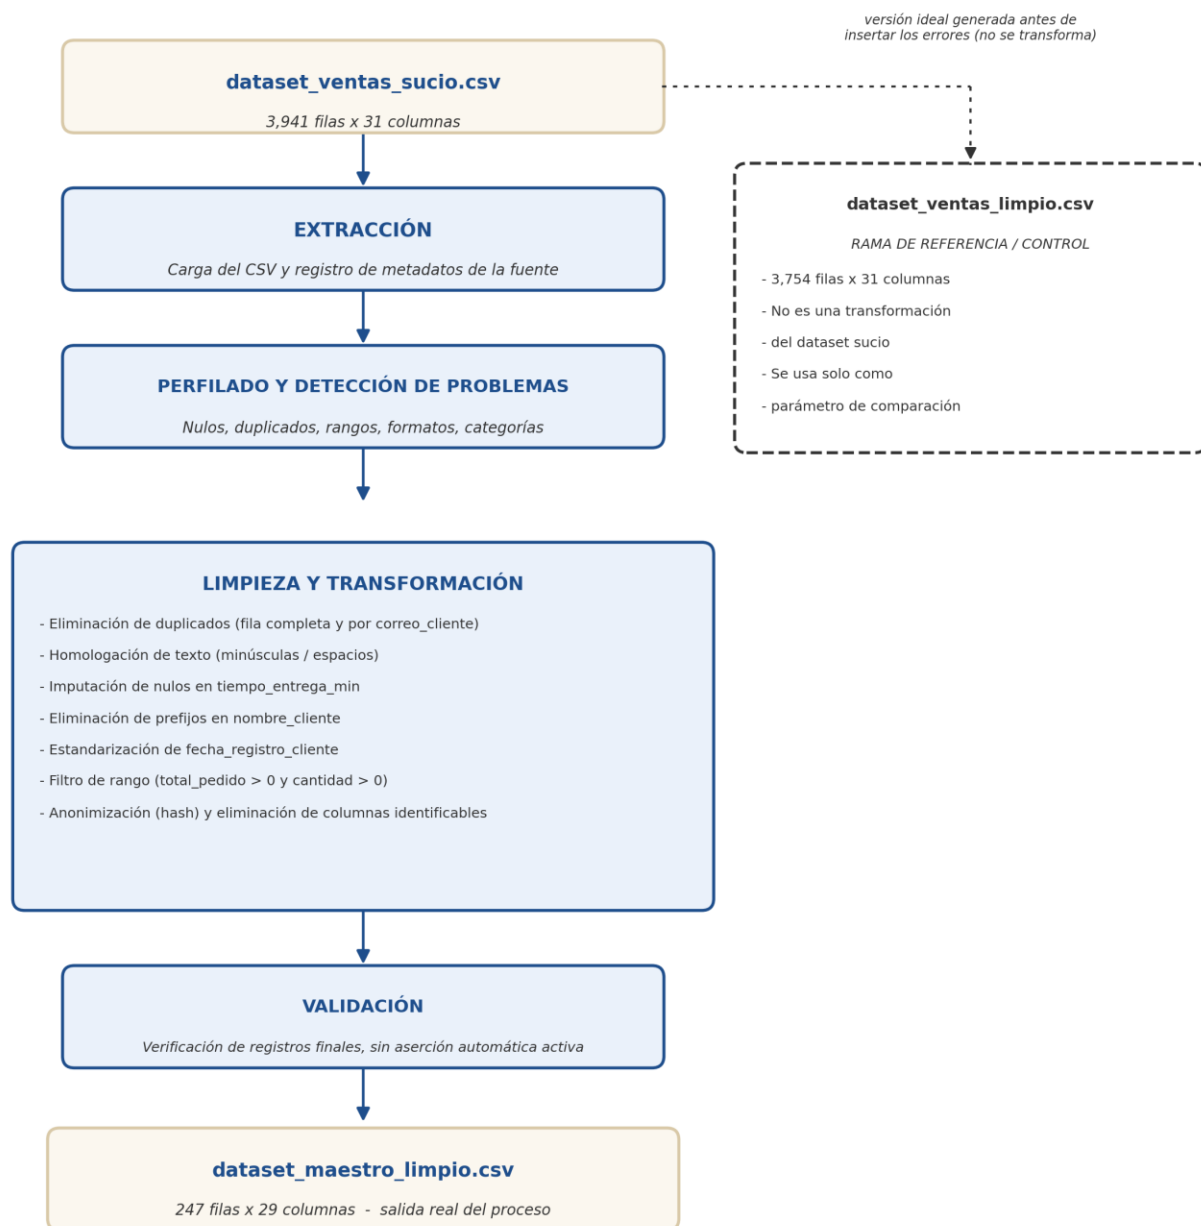
La tabla siguiente resume los archivos que participan en el proyecto, su función dentro del proceso y sus dimensiones reales, calculadas directamente sobre cada archivo.

Archivo	Función	Tipo	Dimensiones
dataset_ventas_sucio.csv	Entrada del ETL	CSV	3,941 filas × 31 columnas
dataset_ventas_limpio.csv	Referencia ideal / control	CSV	3,754 filas × 31 columnas
dataset_maestro_limpio.csv	Salida real del proceso implementado	CSV	247 filas × 29 columnas
generar_dataset_ventas.py	Generación y contaminación controlada	Script	No aplica
Proceso de limpieza y transformación	Limpieza y transformación	Proceso	No aplica
Diccionario_Datos_Cafeteria	Referencia estructural (modelo de datos)	Documento	10 entidades documentadas
script_tablas.sql	Modelo físico de la base de datos	SQL	10 tablas
script_triggers.sql	Validaciones y bitácora automáticas	SQL	29 disparadores (triggers)

Tabla 3.1 — Fuentes de datos del proyecto y sus dimensiones reales.

3.4 Diagrama ETL

El siguiente diagrama representa el flujo real del proceso ETL implementado. El dataset de referencia (dataset_ventas_limpio.csv) se muestra en una rama independiente, ya que no es una transformación directa del dataset sucio, sino la versión ideal generada antes de insertar los errores; se emplea únicamente como parámetro de comparación.



3.5 Extracción

Atributo	Valor
Archivo de origen	dataset_ventas_sucio.csv
Número real de filas	3,941
Número real de columnas	31
Formato	CSV, codificación UTF-8 con BOM
Variables (columnas)	id_venta, id_pedido, id_cliente, nombre_cliente, correo_cliente, fecha_registro_cliente, canal_venta, categoria_producto, producto, cantidad, precio_unitario, subtotal_linea, tipo_pedido, con_reservacion, id_mesa, ubicacion_mesa, tipo_mesa, fecha_reservacion, estado_reservacion, fecha_pedido, hora_pedido, estado_pedido, metodo_pago, estado_pago,

Atributo	Valor
	subtotal_pedido, impuestos, total_pedido, tiempo_entrega_min, calificacion_servicio, tipo_cliente, origen_ecommerce
Tipos observados	Numéricos (id_venta, id_pedido, id_cliente, cantidad), decimales (precio_unitario, subtotal_linea, subtotal_pedido, impuestos, total_pedido, tiempo_entrega_min, calificacion_servicio), texto (identificadores de cliente, categorías, estados, fechas y horas capturadas como cadena) y booleano (con_reservacion, origen_ecommerce), aunque con inconsistencias de tipo introducidas deliberadamente (por ejemplo con_reservacion mezcla valores booleanos con cadenas como "Sí", "1" o "N").
Periodo temporal	No determinado con certeza a partir de dataset_ventas_sucio.csv, debido a que la columna fecha_pedido mezcla múltiples formatos de fecha. Sobre el dataset de referencia (dataset_ventas_limpio.csv), el periodo cubierto va del 2025-01-03 al 2026-08-19.
Unidad de análisis	Cada fila representa una línea de producto dentro de un pedido (equivalente al detalle de pedido del modelo de datos), no un pedido completo ni un cliente. Un mismo pedido puede estar representado por varias filas.

Tabla 5.1 — Metadatos de extracción del archivo fuente.

3.6 Perfilado inicial

El perfilado se realizó directamente sobre dataset_ventas_sucio.csv (3,941 filas, 31 columnas). La siguiente tabla resume los problemas de calidad detectados.

Aspecto evaluado	Resultado
Registros	3,941
Columnas	31
Nulos totales	15,161 valores nulos distribuidos en 14 columnas
Duplicados de fila completa	26 filas
Duplicados por id_venta	187 filas comparten un id_venta ya utilizado por otra fila
Correos con valor nulo / correos únicos válidos	353 filas sin correo (NaN); solo 254 valores de correo distintos no nulos
Campos incompletos (placeholders como "N/A", "-", "???", "sin dato", cadena vacía)	80 en nombre_cliente, 85 en correo_cliente, 83 en producto, 84 en ubicacion_mesa
Categorías inconsistentes en categoria_producto	29 valores distintos observados para 6 categorías reales (23 variantes por mayúsculas, espacios o errores ortográficos)
Categorías inconsistentes en canal_venta	14 valores distintos observados para 3 canales reales (11 variantes)
Categorías inconsistentes en estado_pedido	16 valores distintos observados para 4 estados reales (12 variantes, incluida la grafía "entregao")
Representaciones inconsistentes de con_reservacion	10 valores distintos observados para un campo booleano ("False", "false", "No", "N", "0", "True", "true", "Sí", "S", "1")
Valores fuera de rango — precio_unitario negativo	166 filas
Valores fuera de rango — cantidad (0, -1, 500 o 999 unidades)	141 filas
Valores fuera de rango — calificacion_servicio (fuera de 1–5)	141 filas
Valores fuera de rango — tiempo_entrega_min (negativo o mayor a 300 minutos)	73 filas
Filas con total_pedido menor o igual a cero	39 filas
Fechas con formato distinto al estándar AAAA-MM-DD — fecha_pedido	391 filas
Fechas con formato distinto al estándar AAAA-MM-DD — fecha_registro_cliente	409 filas
Fechas con formato distinto al estándar AAAA-MM-DD — fecha_reservacion	102 filas (de 955 con reservación registrada)

Tabla 6.1 — Resumen del perfilado inicial de dataset_ventas_sucio.csv.

3.7 Registro de transformaciones

A continuación se documentan, en el orden en que aparecen implementadas en el proceso de limpieza y transformación, únicamente las operaciones que realmente se ejecutan sobre los datos.

Nº	Transformación	Campo(s)	Problema tratado	Registros afectados	Resultado
1	Eliminación de duplicados de fila completa	Todas las columnas	Filas idénticas en su totalidad	26	3,941 → 3,915 filas
2	Eliminación de duplicados por correo_cliente (conserva la primera coincidencia)	correo_cliente	Múltiples filas con el mismo valor de correo (incluye nulos y placeholders agrupados como un solo valor)	3,660	3,915 → 255 filas
3	Homologación de texto (recorte de espacios y conversión a minúsculas)	Todas las columnas de tipo texto	Inconsistencias de mayúsculas/minúsculas y espacios	255 filas con valores modificados; no elimina filas	255 filas (sin cambio de conteo)
4	Imputación de valores nulos	tiempo_entrega_min	52 valores nulos	52 valores modificados (rellenados con el texto "15"); no elimina filas	255 filas (sin cambio de conteo)
5	Eliminación de prefijos académicos ("Dr.", "Ing.", "Lic.", "Mtro.", "Dra.", "Sr.", "Srita.", "Sra.")	nombre_cliente	Prefijos capturados junto al nombre	No determinado a partir de los archivos proporcionados (la columna se elimina en un paso posterior y no persiste en la salida final)	255 filas (sin cambio de conteo)
6	Reemplazo de dominio de correo ("correo.com" → "gmail.com")	correo_cliente	Dominio de correo no deseado	No determinado a partir de los archivos proporcionados (la columna se elimina en un paso posterior y no persiste en la salida final)	255 filas (sin cambio de conteo)
7	Estandarización de formato de fecha (a AAAA-MM-DD)	fecha_registro_cliente	19 valores con formato distinto al estándar, sobre las 255 filas restantes	19 valores modificados; no elimina filas	255 filas (sin cambio de conteo)
8	Filtro de rango válido	total_pedido, cantidad	Valores de total_pedido o cantidad menores o iguales a cero	8	255 → 247 filas
9	Anonimización por hash (SHA-256 truncado a 12 caracteres)	id_cliente → nueva columna cliente_id_anon	Identificador de cliente en texto plano	247 valores generados	Se agrega la columna cliente_id_anon
10	Eliminación de columnas identificables	id_cliente, nombre_cliente, correo_cliente	Datos personales en texto plano	3 columnas eliminadas	31 → 29 columnas en la salida final

Tabla 7.1 — Registro de transformaciones efectivamente implementadas.

Es importante señalar que, aunque el proceso incluye pasos de consulta orientados a identificar categorías mal escritas, canales de venta y estados de pedido con errores tipográficos, calificaciones fuera de rango o tiempos de entrega inválidos, no se implementó ninguna operación de corrección para esos campos más allá de la homologación de mayúsculas y espacios (transformación 3). Esta observación se retoma con evidencia cuantitativa en la sección 12 (Validación).

3.8 Trazabilidad de registros

Para reconstruir con exactitud el efecto de cada instrucción sobre el número de filas, se replicó paso a paso la secuencia de operaciones documentada en la sección anterior, partiendo de dataset_ventas_sucio.csv. El resultado de esta réplica coincide de manera exacta con dataset_maestro_limpio.csv (mismas 247 filas y mismos identificadores de venta), lo que permite tener certeza sobre en qué instrucción ocurre cada reducción de registros.

Etapas	Registros antes	Registros afectados / eliminados	Registros después
1. Carga inicial (dataset_ventas_sucio.csv)	—	—	3,941
2. Eliminación de duplicados de fila completa	3,941	26 eliminados	3,915
3. Eliminación de duplicados por correo_cliente (keep = "primero")	3,915	3,660 eliminados	255
4. Homologación de texto	255	0 eliminados (valores modificados)	255
5. Imputación de nulos en tiempo_entrega_min	255	0 eliminados (valores modificados)	255
6. Estandarización de fecha_registro_cliente	255	0 eliminados (valores modificados)	255
7. Filtro de rango (total_pedido > 0 y cantidad > 0)	255	8 eliminados	247
8. Anonimización y eliminación de columnas identificables	247	0 eliminados	247
Salida final (dataset_maestro_limpio.csv)	—	—	247

Tabla 8.1 — Trazabilidad de registros a través de cada etapa del proceso (verificada mediante réplica exacta del procesamiento).

La reducción determinante ocurre en la etapa 3: la instrucción elimina duplicados usando como criterio (subset exclusivamente la columna correo_cliente, conservando solo la primera fila para cada valor distinto que aparezca en esa columna. Técnicamente, esto significa que dos filas se consideran "duplicadas" —y por lo tanto una de ellas se descarta— si comparten el mismo valor de correo_cliente, sin importar si corresponden a la misma venta, a distintas líneas de un mismo pedido, a pedidos diferentes del mismo cliente realizados en fechas distintas, o incluso a clientes completamente distintos que comparten un mismo valor faltante o incompleto en ese campo (por ejemplo, dos personas distintas cuyo correo quedó capturado como "-", "sin dato", "???" o en blanco se tratan como si fueran la misma persona).

En total se eliminaron 3,694 de las 3,941 filas originales (93.7% del dataset de entrada) a lo largo de todo el proceso, de las cuales 3,660 filas (99.1% del total eliminado) se pierden únicamente por este criterio de deduplicación por correo. No se afirma que esta eliminación sea correcta; su idoneidad se evalúa en la siguiente sección con base en la unidad de análisis real del dataset.

3.9 Evaluación de pérdida de información

El campo utilizado para eliminar duplicados (correo_cliente) no representa una venta única ni un pedido único: representa, en el mejor de los casos, a un cliente. En el dataset de origen, cada fila corresponde a una línea de producto dentro de un pedido, y un mismo cliente puede —de hecho, lo hace con frecuencia— realizar múltiples pedidos en fechas distintas, así como pedidos que incluyen varios productos en varias líneas. El análisis directo de los datos confirma que este supuesto se cumple de forma extendida en el dataset.

Métrica	Antes (dataset sucio)	Después (salida del ETL)
Líneas de venta (filas totales)	3,941	247 (–93.7%)
Pedidos únicos (id_pedido)	1,500	247 (–83.5%)

Métrica	Antes (dataset sucio)	Después (salida del ETL)
Clientes distintos (id_cliente)	250	244 identificadores anónimos (-2.4%)
Pedidos que contienen más de una línea de producto	1,150 de 1,500 (76.7%)	0 de 247 (0%)

Tabla 9.1 — Comparación de pedidos, clientes y líneas de venta antes y después del proceso.

El hallazgo más relevante es que, en la salida del proceso, el 100% de los pedidos quedaron representados por una sola línea de producto, cuando en el dataset original el 76.7% de los pedidos (1,150 de 1,500) contenían más de una línea. Esto indica que la deduplicación por correo_cliente no solo elimina pedidos repetidos de un mismo cliente, sino que también elimina, dentro de un mismo pedido, todas las líneas de producto salvo la primera que encuentra el algoritmo, ya que todas ellas comparten el mismo correo.

Adicionalmente, se verificó que múltiples clientes distintos comparten el mismo valor de correo_cliente cuando este es un dato faltante o incompleto: 23 clientes distintos comparten el valor "-", 24 clientes distintos comparten "sin dato", 18 clientes distintos comparten "???", 19 clientes distintos comparten un espacio en blanco, y 353 filas adicionales tienen el valor nulo (NaN), que pandas también agrupa como un único valor a efectos de duplicados. En estos casos, la eliminación de duplicados no solo descarta compras legítimas de un mismo cliente, sino que fusiona a personas distintas como si fueran una sola.

Clasificación de la pérdida de información: potencialmente problemática.

Se clasifica como potencialmente problemática y no como esperada o justificada porque el campo utilizado no corresponde a la unidad de análisis del dataset (línea de venta) ni siquiera a un identificador confiable de cliente cuando el correo está ausente o incompleto. El resultado observado (una reducción de 3,941 a 247 filas, y de 1,500 a 247 pedidos) es consistente con este mecanismo y no con un criterio de limpieza dirigido específicamente a duplicados reales de captura.

3.10 Tratamiento de datos personales

El proceso implementado aplica dos mecanismos distintos sobre los datos personales presentes en el dataset:

- nombre_cliente y correo_cliente: se eliminan por completo del dataset de salida (no se conservan en ninguna forma, ni siquiera enmascarada). Esto es adecuado como medida de minimización de datos, siempre que la información que aportaban (nombre, correo) no sea necesaria para el análisis posterior.
- id_cliente: se sustituye por una nueva columna, cliente_id_anon, generada aplicando la función hash criptográfica SHA-256 al valor del identificador y truncando el resultado a los primeros 12 caracteres hexadecimales.

Respecto al nivel de anonimización que puede demostrarse con la información disponible: el valor de entrada al hash (id_cliente) es un número entero secuencial que, según el script de generación de datos, toma únicamente valores entre 1 y 250. No se observa evidencia en el código de que se agregue un valor aleatorio o "sal" (salt) antes de aplicar el hash. Esto significa que, en principio, sería posible reconstruir la tabla de equivalencia entre cada cliente_id_anon y su id_cliente original probando los 250 valores posibles y comparando los hashes resultantes. No se afirma, por tanto, que este mecanismo constituya una anonimización robusta o irreversible; desde un punto de vista técnico, corresponde más a una seudonimización débil, dado el tamaño reducido y predecible del espacio de valores de entrada.

No se encontró evidencia en los archivos proporcionados de que exista un proceso adicional de gestión de claves, rotación de sal criptográfica, o cualquier otro control complementario de seguridad sobre este campo. No determinado a partir de los archivos proporcionados si dicho control existe fuera del alcance de los archivos entregados.

3.11 Comparación de datasets

Métrica	Dataset sucio	Dataset ideal de referencia	Dataset producido por el ETL
Filas	3,941	3,754	247
Columnas	31	31	29
Pedidos únicos	1,500	1,500	247
Cientes / identificadores disponibles	250 (id_cliente)	250 (id_cliente)	244 (cliente_id_anon, hash)
Duplicados de fila completa	26	0	0
Nulos (total)	15,161	12,891	869
Pedidos con más de una línea de producto	1,150 (76.7%)	1,129 (75.3%)	0 (0%)

Tabla 11.1 — Comparación cuantitativa de los tres datasets del proyecto.

La comparación evidencia que, si bien el dataset de referencia (columna intermedia) conserva prácticamente la misma estructura y volumen que el dataset sucio —como corresponde a una versión "ideal" del mismo universo de datos, sin los errores insertados—, la salida real del proceso implementado se aleja de manera considerable de ambos, tanto en número de filas como en la proporción de pedidos con más de una línea de producto.

3.12 Validación

Se evaluó dataset_maestro_limpio.csv (salida real del proceso) contra los criterios solicitados, comparando cuando fue posible contra dataset_ventas_limpio.csv como referencia.

Criterio	Resultado de la validación
Duplicados de fila completa	0 filas duplicadas. Criterio superado.
Identificadores (id_venta)	0 valores de id_venta duplicados en las 247 filas finales. Criterio superado.
Nulos	869 valores nulos remanentes en 10 de las 29 columnas. La mayoría corresponde a nulos estructurales legítimos (por ejemplo id_mesa, ubicacion_mesa, tipo_mesa, fecha_reservacion y estado_reservacion en pedidos sin reservación, o calificacion_servicio en pedidos no entregados), pero también persisten 4 valores nulos en fecha_registro_cliente (generados por la conversión de fecha, que descarta como no válido cualquier texto que no logra interpretar) y 5 valores nulos en producto.
Tipos de datos	tiempo_entrega_min se rellenó como texto ("15") durante el proceso; en el archivo final se reincorpora como numérico decimal gracias a la reinterpretación de tipos que ocurre al exportar y volver a leer el CSV, no por una conversión explícita de tipo en el proceso.
Rangos — precio_unitario	14 filas con precio_unitario negativo. El proceso no incluye ninguna corrección de este campo; el error persiste sin cambios respecto al dataset sucio.
Rangos — cantidad	0 filas con cantidad menor o igual a cero (corregido por el filtro de rango), pero 9 filas conservan cantidades no realistas (500 o 999 unidades), ya que el filtro solo excluye valores no positivos, sin límite superior.
Rangos — calificacion_servicio	9 valores fuera del rango válido de 1 a 5 (incluye 0, 6, 8, 10 y -2). No se aplicó ninguna corrección a este campo.
Rangos — tiempo_entrega_min	3 valores fuera de un rango operativo razonable (-15, 500 y 720 minutos). No se aplicó ninguna corrección a este campo.
Fechas — fecha_registro_cliente	0 de 243 valores no nulos con formato distinto al estándar AAAA-MM-DD. Único campo de fecha efectivamente estandarizado.
Fechas — fecha_pedido	29 de 247 valores (11.7%) conservan un formato distinto al estándar. No se aplicó estandarización a este campo.
Fechas — fecha_reservacion	7 de 63 valores no nulos (11.1%) conservan un formato distinto al estándar. No se aplicó estandarización a este campo.
Categorías — categoria_producto, canal_venta, estado_pedido, con_reservacion	Persisten variantes múltiples para un mismo valor conceptual (16, 9, 5 y 7 variantes distintas respectivamente en la salida final). La homologación de texto solo unifica mayúsculas y espacios; no corrige errores ortográficos ni unifica representaciones booleanas.

Criterio	Resultado de la validación
Relaciones lógicas — subtotal_linea = precio_unitario × cantidad	21 de 227 filas evaluables (9.3%) presentan una diferencia mayor a 0.05 respecto al valor esperado.
Relaciones lógicas — total_pedido = subtotal_pedido + impuestos	10 de 247 filas (4.0%) presentan una diferencia mayor a 0.05 respecto al valor esperado.

Tabla 12.1 — Resultados de validación del dataset producido por el proceso ETL.

3.13 Carga / Salida

dataset_maestro_limpio.csv se genera mediante la exportación directa del dataframe resultante a un archivo CSV, guardado en una carpeta de Google Drive vinculada al entorno de ejecución (ruta del tipo BD_Cafeteria/dataset/etapa_3/dataset_maestro_limpio.csv).

A partir de los archivos proporcionados no se encontró evidencia de que el dataset resultante haya sido efectivamente cargado a una base de datos MySQL: el proceso de limpieza y transformación no incluye ninguna instrucción de conexión, ni sentencias de inserción hacia las tablas definidas en script_tablas.sql. Los scripts script_tablas.sql y script_triggers.sql definen la estructura física y las validaciones automáticas (bitácora de auditoría) de una base de datos relacional, pero constituyen un artefacto independiente, sin un punto de integración visible con el proceso de limpieza documentado en este informe. No se afirma, por tanto, que exista una carga efectiva a la base de datos; únicamente se confirma la generación del archivo CSV.

3.14 Registro general de transformaciones

ID	Etapas	Transformación	Motivo	Resultado	Evidencia
T1	Limpieza	Eliminación de duplicados de fila completa	Filas idénticas en su totalidad	3,941 → 3,915 filas	drop_duplicates() sobre df
T2	Limpieza	Eliminación de duplicados por correo_cliente	Deduplicar por cliente (criterio potencialmente problemático, ver sección 9)	3,915 → 255 filas	drop_duplicates(subset=['correo_cliente'], keep='first')
T3	Transformación	Homologación de texto (minúsculas y espacios)	Inconsistencias de formato de texto	255 valores de texto normalizados en mayúsculas/espacios; sin cambio en filas	.str.strip().str.lower() sobre columnas de texto
T4	Limpieza	Imputación de nulos en tiempo_entrega_min	52 valores nulos	52 valores rellenados con "15"; sin cambio en filas	fillna('15')
T5	Transformación	Eliminación de prefijos académicos en nombre_cliente	Prefijos capturados junto al nombre	No determinado a partir de los archivos proporcionados (columna eliminada después)	str.replace() con expresión regular sobre nombre_cliente
T6	Transformación	Reemplazo de dominio de correo	Dominio "correo.com" no deseado	No determinado a partir de los archivos proporcionados (columna eliminada después)	str.replace() con expresión regular sobre correo_cliente
T7	Transformación	Estandarización de fecha_registro_cliente	19 valores con formato no estándar	255 filas; 19 valores convertidos a AAAA-MM-DD	pd.to_datetime(...).dt.strftime('%Y-%m-%d')

ID	Etapas	Transformación	Motivo	Resultado	Evidencia
T8	Limpieza	Filtro de rango (total_pedido > 0 y cantidad > 0)	39 filas con total_pedido ≤ 0 y 60 con cantidad ≤ 0 detectadas en el perfilado inicial	255 → 247 filas	Filtro booleano sobre df
T9	Anonimización	Hash SHA-256 (12 caracteres) sobre id_cliente	Identificador de cliente en texto plano	Columna cliente_id_anon creada para 247 filas	hashlib.sha256(...).hexdigest()[:12]
T10	Anonimización	Eliminación de columnas identificables	Datos personales en texto plano (id_cliente, nombre_cliente, correo_cliente)	31 → 29 columnas en la salida final	df.drop(columns=[...])

Tabla 14.1 — Registro general de todas las transformaciones aplicadas.

3.15 Hallazgos técnicos

15.1 Errores de los datos (presentes en la fuente, no atribuibles al proceso)

- Nulos, duplicados, fechas con formatos mixtos, categorías mal escritas, valores fuera de rango, montos atípicos y campos incompletos, todos ellos introducidos deliberadamente en dataset_ventas_sucio.csv según se documenta en generar_dataset_ventas.py.

15.2 Transformaciones correctamente ejecutadas

- Eliminación de duplicados de fila completa (26 filas).
- Estandarización completa del formato de fecha_registro_cliente (0 valores no estándar remanentes).
- Filtro de registros con total_pedido o cantidad no positivos.
- Eliminación de columnas con datos personales en texto plano (nombre_cliente, correo_cliente, id_cliente).

15.3 Decisiones de limpieza cuya idoneidad es cuestionable

- La deduplicación por correo_cliente (keep='first') es, con la evidencia disponible, la decisión de mayor impacto y la de idoneidad más cuestionable de todo el proceso: elimina el 93% de las filas del dataset, reduce los pedidos de 1,500 a 247 y hace desaparecer por completo los pedidos multilínea (de 76.7% a 0%), además de fusionar clientes distintos que comparten un correo faltante o incompleto.
- La imputación del valor nulo de tiempo_entrega_min con la cadena de texto "15" (en lugar de un valor numérico) introduce un tipo de dato mixto dentro de la columna durante el procesamiento; el archivo final solo aparece con tipo numérico consistente porque la exportación e importación del CSV reinterpretan el tipo, no porque el proceso lo haya convertido explícitamente.

15.4 Posibles problemas metodológicos

- La verificación de integridad de registros incluida en el proceso (sección "comprobación de que no se perdieron registros sin explicación") calcula un valor esperado de registros que solo contempla la eliminación de duplicados de fila completa, sin incorporar la eliminación por correo_cliente ni el filtro de rango posterior; la aserción de validación automática aparece desactivada (comentada) en el propio código, por lo que el proceso no cuenta con una verificación automática y activa de la cantidad de registros perdidos.

- Los pasos de consulta para identificar categorías mal escritas (`canal_venta`, `estado_pedido`), calificaciones fuera de rango, tiempos de entrega inválidos y precios negativos no tienen una transformación de corrección correspondiente; el proceso homologa mayúsculas y espacios pero no corrige la ortografía ni los valores fuera de rango en esos campos, lo que se confirma en la validación de la sección 12 (por ejemplo, 14 precios negativos y 16 variantes de `categoria_producto` siguen presentes en la salida final).
- No se encontró evidencia de una etapa de carga hacia una base de datos relacional (ver sección 13), pese a que el proyecto cuenta con un modelo físico y triggers de auditoría ya definidos para ese fin.

3.16 Conclusión

El dataset de entrada (`dataset_ventas_sucio.csv`) partió de 3,941 filas y 31 columnas con errores de captura representativos de un entorno real: nulos, duplicados, formatos de fecha mixtos, categorías mal escritas, valores fuera de rango y campos incompletos. El proceso de limpieza y transformación implementado aplicó diez operaciones sobre esos datos, de las cuales las más determinantes en términos de volumen fueron la eliminación de duplicados de fila completa y, sobre todo, la eliminación de duplicados por `correo_cliente`, que por sí sola redujo el dataset en un 93.5% adicional.

El estado final —`dataset_maestro_limpio.csv`, con 247 filas y 29 columnas— sí presenta mejoras verificables respecto al dataset de entrada: no contiene duplicados de fila completa, el campo `fecha_registro_cliente` quedó completamente estandarizado, los registros con montos o cantidades no positivos fueron descartados, y los datos personales en texto plano fueron eliminados o sustituidos por un identificador derivado de hash.

Sin embargo, la validación realizada en este documento muestra que el resultado conserva limitaciones importantes: persisten precios negativos, calificaciones y tiempos de entrega fuera de rango, y múltiples variantes no corregidas en los campos categóricos; dos de los tres campos de fecha nunca fueron estandarizados; y, de manera más relevante, el criterio de deduplicación aplicado no corresponde a la unidad de análisis del dataset (línea de venta), lo que provocó la pérdida del 83.5% de los pedidos y la desaparición total de los pedidos con más de un producto, una pérdida de información clasificada en este documento como potencialmente problemática y no como el resultado esperado de una limpieza de duplicados legítimos.

En consecuencia, no puede afirmarse que el proceso ETL haya sido completamente exitoso. El dataset resultante es adecuado únicamente para un análisis muy acotado a nivel de "último pedido representativo por cliente", pero no resulta adecuado, en su estado actual, para análisis que requieran preservar la totalidad de las transacciones, el detalle multilínea de los pedidos, o rangos de valores plenamente validados. Se recomienda revisar el criterio de deduplicación utilizado —idealmente basado en la combinación de `id_pedido` y `producto`, o en un identificador de venta único— y completar las correcciones de rango y de estandarización de fecha que quedaron pendientes, antes de emplear este dataset como fuente definitiva para los KPI y dashboards de Café Cereza.