

# CAFÉ CEREZA

- *Página web con sistema de reservaciones para una cafetería universitaria* -



Analítica de Datos para Negocios Digitales

## 1. Introducción

---

Café Cereza es una cafetería cuyo proyecto de Tecnologías de la Información contempla un sitio web para dar a conocer el negocio y su catálogo de productos, permitir la reservación de mesas y gestionar pedidos, tanto para consumir en el establecimiento como para llevar. El sistema distingue entre usuarios cliente y administrativos, y conserva una bitácora de auditoría sobre las operaciones realizadas en la base de datos.

Dado que el proyecto se encuentra en una etapa previa a la operación real del negocio, no se contaba con un histórico de ventas propio. Por ello fue necesario construir un dataset de ventas simulado que reprodujera, de forma controlada, el comportamiento esperado de las transacciones de la cafetería: pedidos, productos, clientes, montos, canales de venta y demás variables asociadas al modelo de datos.

La finalidad de esta simulación es contar con un conjunto de datos realista y coherente con el diseño de la base de datos del proyecto, que permita practicar y validar procesos de limpieza de datos, análisis exploratorio, construcción de indicadores y elaboración de dashboards, sin depender de información sensible o inexistente de un negocio real.

Establecer reglas antes de generar los datos es indispensable porque, a diferencia de datos reales, un dataset simulado únicamente será útil para el análisis posterior si sus valores respetan relaciones lógicas coherentes entre sí (por ejemplo, que un total de pedido corresponda efectivamente a la suma de sus líneas de detalle, o que no existan pedidos sin fecha). Sin reglas explícitas, la simulación podría generar datos internamente inconsistentes, lo que invalidaría cualquier análisis o indicador construido a partir de ellos.

Este dataset queda disponible, en su versión limpia, como insumo para las siguientes etapas del proyecto: análisis exploratorio de datos, cálculo de indicadores de desempeño (ventas por periodo, participación del canal en línea, productos más vendidos, entre otros) y construcción de dashboards de visualización. Adicionalmente, se generó una versión "sucia" del mismo dataset, con errores insertados deliberadamente, que sirve como material de práctica para procesos de limpieza y validación de datos.

## 2. Objetivo del documento

---

El presente documento tiene como objetivo documentar de manera clara y formal las reglas utilizadas para generar los datos simulados de ventas de Café Cereza, de modo que cualquier persona pueda comprender la lógica empleada sin necesidad de revisar directamente el código fuente del generador.

De forma específica, este documento busca:

- Describir las características generales del dataset final de ventas.
- Explicar la forma en que se determinó la cantidad de registros generados.
- Documentar, variable por variable, las reglas de generación y los rangos o criterios utilizados.
- Diferenciar entre las tendencias diseñadas explícitamente en el código y los patrones que emergen de la interacción entre reglas.

- Establecer los criterios de validación e integridad que permiten considerar coherente un registro.
- Dejar constancia de las limitaciones propias de trabajar con datos simulados.

### 3. Descripción general del dataset

La descripción siguiente corresponde al archivo `dataset_ventas_limpio.csv`, utilizado como referencia principal para caracterizar los datos finales del proyecto, ya que representa la versión de los datos sin errores insertados deliberadamente.

| Característica                                     | Valor                                                                                                                                                       |
|----------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Nombre del dataset (versión de referencia)         | dataset_ventas_limpio.csv                                                                                                                                   |
| Cantidad de registros (líneas de detalle de venta) | 3,754 filas                                                                                                                                                 |
| Cantidad de variables (columnas)                   | 31 variables                                                                                                                                                |
| Pedidos únicos representados                       | 1,500 pedidos (id_pedido)                                                                                                                                   |
| Cientes únicos representados                       | 250 clientes (id_cliente)                                                                                                                                   |
| Fecha mínima (fecha_pedido)                        | 03 de enero de 2025                                                                                                                                         |
| Fecha máxima (fecha_pedido)                        | 19 de agosto de 2026                                                                                                                                        |
| Periodo temporal cubierto                          | Aproximadamente 20 meses (enero 2025 a agosto 2026)                                                                                                         |
| Unidad de análisis de cada fila                    | Una línea de producto dentro de un pedido (el dataset está "aplanado": un pedido con varios productos genera varias filas que comparten el mismo id_pedido) |

Cada fila del dataset representa un renglón de detalle de pedido (equivalente a la entidad `Detalle_pedido` del modelo de base de datos), e incorpora además, mediante desnormalización deliberada para fines de análisis, información del cliente (Usuario), del pedido (Pedido), de la mesa y reservación asociadas (Mesa y Reservación) y del pago. Cada pedido puede tener entre 1 y 4 líneas de producto.

#### 3.1 Diferencia entre el dataset limpio y el dataset sucio

El archivo `dataset_ventas_sucio.csv` parte exactamente de los mismos 3,754 registros del dataset limpio, pero contiene 3,941 filas: la diferencia de 187 filas corresponde a duplicados insertados deliberadamente (aproximadamente el 5% de las filas originales se duplicó de forma exacta, conservando el mismo `id_venta`, para simular una doble captura). Además de los duplicados, el dataset sucio incorpora, de forma intencional y sobre subconjuntos aleatorios de filas, valores nulos, fechas en distintos formatos de texto, categorías con errores de escritura (mayúsculas, acentos y typos), valores fuera de rango (precios negativos, cantidades absurdas, calificaciones fuera de 1 a 5), datos atípicos en montos, campos de texto vacíos o truncados y representaciones inconsistentes de valores booleanos.

Por lo anterior, el dataset\_ventas\_sucio.csv no debe utilizarse para describir las características finales de los datos, sino únicamente como referencia del estado previo a la limpieza; toda cifra reportada en este documento sobre cantidades, rangos y distribuciones corresponde al dataset limpio.

## 4. Variables consideradas para la simulación

La siguiente tabla describe las 31 variables que componen el dataset limpio, agrupadas en el orden en que aparecen en el archivo. Se indica el tipo de dato observado y la regla utilizada en el código de generación para asignar su valor. Las variables marcadas como "derivada" no se generan de forma independiente, sino que se calculan a partir de otras variables del propio registro.

| Variable               | Descripción                                         | Tipo de dato | Regla de generación o validación                                                                                                                                       |
|------------------------|-----------------------------------------------------|--------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| id_venta               | Identificador único de la línea de venta/detalle.   | Entero       | Correlativo autoincremental, inicia en 1 y aumenta por cada línea generada.                                                                                            |
| id_pedido              | Identificador del pedido al que pertenece la línea. | Entero       | Correlativo que inicia en 1001 y aumenta en 1 por cada nuevo pedido simulado (1,500 pedidos en total).                                                                 |
| id_cliente             | Identificador del cliente que realizó el pedido.    | Entero       | Se toma de un catálogo previo de 250 clientes generados; se elige aleatoriamente un cliente por cada pedido.                                                           |
| nombre_cliente         | Nombre completo del cliente.                        | Texto        | Combinación aleatoria de un nombre y un apellido tomados de listas predefinidas de nombres y apellidos.                                                                |
| correo_cliente         | Correo electrónico del cliente.                     | Texto        | Se construye a partir del nombre, apellido e id_cliente del cliente (nombre.apellido+id@correo.com).                                                                   |
| fecha_registro_cliente | Fecha en que el cliente se registró en el sistema.  | Fecha        | Fecha aleatoria uniforme entre el 1 de enero de 2025 y el 19 de agosto de 2026.                                                                                        |
| canal_venta            | Medio por el cual se realizó la venta.              | Categórico   | Página web, Presencial (mostrador) o Presencial (mesero); ver regla detallada en la sección 6.9-equivalente (6.1 y 6.3 del código, descrita en 6.9 de este documento). |
| categoria_producto     | Categoría del producto vendido.                     | Categórico   | Una de 6 categorías del catálogo, elegida de forma aleatoria uniforme por cada línea de producto.                                                                      |
| producto               | Nombre del producto vendido.                        | Texto        | Elegido aleatoriamente entre los productos que pertenecen a la categoría ya seleccionada (catálogo fijo de 29 productos).                                              |
| cantidad               | Unidades del producto solicitadas en la línea.      | Entero       | Aleatorio uniforme entre 1 y 3 unidades.                                                                                                                               |

| Variable           | Descripción                                                 | Tipo de dato       | Regla de generación o validación                                                                                                               |
|--------------------|-------------------------------------------------------------|--------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| precio_unitario    | Precio de una unidad del producto.                          | Decimal            | Aleatorio uniforme dentro de un rango específico por categoría (ver sección 6.6).                                                              |
| subtotal_linea     | Importe de la línea de producto.                            | Decimal (derivada) | cantidad × precio_unitario, redondeado a 2 decimales.                                                                                          |
| tipo_pedido        | Modalidad del pedido.                                       | Categorico         | "para llevar" o "en el lugar", con la misma probabilidad (50%/50%) por pedido.                                                                 |
| con_reservacion    | Indica si el pedido está asociado a una reservación previa. | Booleano           | Solo puede ser verdadero si tipo_pedido es "en el lugar"; en ese caso, 50% de probabilidad de tener reservación.                               |
| id_mesa            | Mesa asignada al pedido.                                    | Entero             | Número entre 1 y 20, asignado únicamente si tipo_pedido es "en el lugar"; vacío si es "para llevar".                                           |
| ubicacion_mesa     | Zona del local donde se ubica la mesa.                      | Categorico         | Una de 4 zonas (Terraza, Salón principal, Zona de estudio, Barra), asignada solo si hay mesa asociada.                                         |
| tipo_mesa          | Tipo de mesa según capacidad de uso.                        | Categorico         | individual, pareja o grupal; asignado solo si hay mesa asociada.                                                                               |
| fecha_reservacion  | Fecha en que se realizó la reservación previa.              | Fecha              | Solo si con_reservacion es verdadero: entre 0 y 3 días antes de la fecha del pedido.                                                           |
| estado_reservacion | Estado final de la reservación.                             | Categorico         | completada (75%), cancelada (10%), no_show (10%) o pendiente (5%); solo si con_reservacion es verdadero.                                       |
| fecha_pedido       | Fecha en que se generó el pedido.                           | Fecha              | Aleatoria uniforme entre la fecha de registro del cliente (o el 1 de enero de 2025, la que sea posterior) y el 19 de agosto de 2026.           |
| hora_pedido        | Hora en que se generó el pedido.                            | Hora               | Hora entera aleatoria entre 7 y 20, con minutos en múltiplos de 5 (horario de operación: 7:00 a 21:00).                                        |
| estado_pedido      | Estado del pedido en el flujo operativo.                    | Categorico         | entregado (70%), listo (15%), en preparación (10%) o cancelado (5%).                                                                           |
| metodo_pago        | Medio utilizado para pagar el pedido.                       | Categorico         | Si el canal es "Página web", 85% de probabilidad de "pago en línea"; en cualquier otro caso, se elige entre efectivo, tarjeta o transferencia. |
| estado_pago        | Estado de la transacción de pago.                           | Categorico         | "pagado" si el pedido no está cancelado; si está cancelado, "pendiente" o "reembolsado" de forma aleatoria.                                    |
| subtotal_pedido    | Importe del pedido antes de impuestos.                      | Decimal (derivada) | Suma de subtotal_linea de todas las líneas que integran el mismo pedido.                                                                       |

| Variable              | Descripción                                         | Tipo de dato          | Regla de generación o validación                                                                                                                                     |
|-----------------------|-----------------------------------------------------|-----------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| impuestos             | Impuesto aplicado al pedido.                        | Decimal (derivada)    | $\text{subtotal\_pedido} \times 0.16$ , redondeado a 2 decimales (16%).                                                                                              |
| total_pedido          | Importe final del pedido.                           | Decimal (derivada)    | $\text{subtotal\_pedido} + \text{impuestos}$ , redondeado a 2 decimales.                                                                                             |
| tiempo_entrega_min    | Minutos que tardó la entrega del pedido.            | Entero                | Aleatorio entre 8 y 45 minutos, únicamente si estado_pedido es "entregado" o "listo"; vacío en otros casos.                                                          |
| calificacion_servicio | Calificación otorgada por el cliente.               | Entero (1 a 5)        | Solo si estado_pedido es "entregado": 5 (45%), 4 (30%), 3 (15%), 2 (7%) o 1 (3%).                                                                                    |
| tipo_cliente          | Segmento del cliente según su frecuencia de compra. | Categorico (derivada) | Calculado a partir del número real de pedidos del cliente en todo el dataset: 1 pedido = Nuevo; 2-3 = Recurrente; 4-7 = Frecuente; más de 7 = VIP (ver sección 6.3). |
| origen_ecommerce      | Indica si el pedido se originó en el canal web.     | Booleano (derivada)   | Verdadero únicamente cuando canal_venta es igual a "Página web".                                                                                                     |

El prompt de referencia de este documento solicita analizar también variables de edad, género, promoción, descuento y empleado asignado a la venta. Ninguna de estas cinco variables está presente en el dataset ni en el script de generación revisado; por lo tanto, conforme a la instrucción de no inventar información, se reporta lo siguiente: la generación no contempla edad ni género del cliente, no existe mecanismo de promociones ni de descuentos sobre el total del pedido, y no se asigna un empleado responsable a cada venta. Estas cinco variables corresponden a "No determinado a partir de los archivos proporcionados".

## 5. Cantidad de registros

La cantidad de registros del dataset está determinada por dos parámetros fijados explícitamente al inicio del script `generar_dataset_ventas.py`: `N_CLIENTES = 250` y `N_PEDIDOS = 1500`. A partir de estos dos valores, el generador construye 1,500 pedidos, cada uno con un número aleatorio de líneas de producto entre 1 y 4, lo que produce las 3,754 filas finales del dataset limpio (equivalente a un promedio de 2.5 líneas por pedido).

La cantidad de 1,500 pedidos no responde a una fórmula matemática, sino a una constante definida directamente en el código como el volumen de pedidos que se desea simular para el periodo de análisis (poco más de un año y medio de operación, del 1 de enero de 2025 al 19 de agosto de 2026). De la misma manera, los 250 clientes representan la base de usuarios simulada sobre la cual se distribuyen esos 1,500 pedidos.

### 5.1 Distribución mensual de pedidos

Tomando como base el dataset limpio y contando una sola vez cada id\_pedido (para no duplicar por las múltiples líneas de un mismo pedido), la distribución de pedidos por mes calendario es la siguiente:

| Mes     | Pedidos |
|---------|---------|
| 2025-01 | 1       |
| 2025-02 | 5       |
| 2025-03 | 6       |
| 2025-04 | 19      |
| 2025-05 | 26      |
| 2025-06 | 32      |
| 2025-07 | 34      |
| 2025-08 | 39      |
| 2025-09 | 44      |
| 2025-10 | 57      |
| 2025-11 | 58      |
| 2025-12 | 72      |
| 2026-01 | 70      |
| 2026-02 | 86      |
| 2026-03 | 94      |
| 2026-04 | 108     |
| 2026-05 | 130     |
| 2026-06 | 161     |
| 2026-07 | 227     |
| 2026-08 | 231*    |

*\* El mes de agosto de 2026 está incompleto en el dataset, ya que la fecha de corte de la simulación (FECHA\_FIN) es el 19 de agosto de 2026; por ello no debe compararse directamente con el resto de los meses, que sí están completos.*

La cantidad de registros resulta adecuada para el objetivo del dataset: un volumen de 1,500 pedidos y 3,754 líneas de detalle es suficiente para calcular indicadores agregados (ventas por mes, por categoría, por canal) con una base estadística razonable, sin que el archivo resulte excesivamente pesado para fines de análisis exploratorio y construcción de dashboards en un proyecto universitario.

## 6. Reglas de simulación

---

En esta sección se documentan, variable por variable, las reglas reales implementadas en `generar_dataset_ventas.py` para producir cada dato. Cuando una variable no está contemplada en el código, así se indica expresamente.

## 6.1 Generación de fechas

El script define tres fechas de control:

- `FECHA_INICIO` = 1 de enero de 2025 (arranque de operaciones del negocio simulado).
- `FECHA_LANZAMIENTO_WEB` = 1 de julio de 2025 (fecha en que se lanzó el canal de venta "Página web").
- `FECHA_FIN` = 19 de agosto de 2026 (fecha de corte de la simulación, tratada como "hoy").

La fecha de registro de cada cliente (`fecha_registro_cliente`) se genera de forma aleatoria uniforme entre `FECHA_INICIO` y `FECHA_FIN`, mediante una función que calcula el número de días entre ambas fechas y selecciona un desplazamiento aleatorio dentro de ese rango. La fecha de cada pedido (`fecha_pedido`) se genera con la misma lógica de aleatoriedad uniforme, pero restringida a partir de la fecha de registro del cliente correspondiente (o de `FECHA_INICIO`, la que sea posterior), de manera que ningún pedido pueda ocurrir antes de que el cliente exista en el sistema. No se identificó en el código una restricción o distribución explícita por mes o por día de la semana: ambas variables se derivan matemáticamente de `fecha_pedido` una vez generada, no se generan de forma independiente.

## 6.2 Generación de horarios

La hora de cada pedido (`hora_pedido`) se genera mediante una función que selecciona una hora entera aleatoria uniforme entre las 7 y las 20 horas, y minutos aleatorios entre un conjunto fijo de múltiplos de 5 (00, 05, 10, ..., 55). Esta regla refleja, según el comentario del propio código, que la cafetería opera de 7:00 a 21:00 horas. No existe en el código una distribución que favorezca ciertas horas como de mayor actividad: la selección es uniforme entre las 14 horas del rango permitido, por lo que cualquier concentración observada en un horario específico dentro del dataset final corresponde a variación aleatoria y no a una regla de diseño.

## 6.3 Generación de clientes

El catálogo de clientes se genera de forma previa e independiente a los pedidos: se crean 250 clientes, cada uno con un identificador correlativo (`id_cliente`), un nombre y apellido tomados de listas predefinidas, un correo construido a partir de esos datos, un teléfono simulado y una fecha de registro aleatoria. Para cada pedido, el cliente se elige de forma aleatoria uniforme entre los 250 clientes ya existentes (con reemplazo, es decir, un mismo cliente puede tener varios pedidos).

El campo `tipo_cliente` no se asigna al momento de crear al cliente, sino que se calcula al final, contando cuántos pedidos reales tuvo cada cliente a lo largo de todo el dataset y clasificándolo de la siguiente manera: 1 pedido = Nuevo; de 2 a 3 pedidos = Recurrente; de 4 a 7 pedidos = Frecuente; más de 7 pedidos = VIP. El código contempla también la categoría "Inactivo" para clientes con 0 pedidos, pero, dado que todo cliente generado necesariamente tiene al menos un pedido asociado en la simulación, esta categoría no aparece en el dataset final.



El código no contempla edad ni género del cliente en ninguna de sus estructuras de datos, por lo que estas variables se reportan como no determinadas a partir de los archivos proporcionados.

## 6.4 Generación de productos

El catálogo de productos está definido de forma fija en el código mediante un diccionario de 6 categorías (Café caliente, Café frío, Repostería, Alimentos, Bebidas frías y Bebidas calientes), cada una con una lista de productos específicos, sumando 29 productos en total. Para cada línea de un pedido, primero se elige una categoría de forma aleatoria uniforme entre las 6 disponibles, y después se elige un producto de forma aleatoria uniforme entre los productos que pertenecen a esa categoría. Esta secuencia garantiza que todo producto generado pertenezca siempre a una categoría válida y coherente con el catálogo definido.

## 6.5 Generación de cantidades

La cantidad de unidades por línea de producto (cantidad) se genera como un entero aleatorio uniforme entre 1 y 3 unidades. Cada pedido puede tener entre 1 y 4 líneas de producto (también un entero aleatorio uniforme), por lo que un mismo pedido puede incluir hasta 4 productos distintos, cada uno con su propia cantidad entre 1 y 3.

## 6.6 Generación de precios

El precio unitario de cada producto (precio\_unitario) se genera de forma aleatoria uniforme dentro de un rango específico según la categoría a la que pertenece el producto, y no según el producto individual. Los rangos definidos en el código son los siguientes:

| Categoría         | Rango de precio unitario |
|-------------------|--------------------------|
| Café caliente     | \$28.00 – \$55.00        |
| Café frío         | \$35.00 – \$65.00        |
| Repostería        | \$25.00 – \$60.00        |
| Alimentos         | \$45.00 – \$95.00        |
| Bebidas frías     | \$20.00 – \$40.00        |
| Bebidas calientes | \$25.00 – \$45.00        |

Esto implica que dos unidades del mismo producto (por ejemplo, dos "Latte") pueden registrar precios unitarios distintos entre diferentes pedidos, ya que el precio no está fijado por producto en un catálogo estático, sino que se genera de forma independiente en cada línea dentro del rango de su categoría. El dataset limpio confirma esta lógica: el precio\_unitario observado va de \$20.03 a \$94.99, consistente con la unión de todos los rangos por categoría.

## 6.7 Generación del total

El total de una venta se calcula de forma completamente derivada, en tres pasos, y no se genera de manera aleatoria en ningún momento:

- $\text{subtotal\_linea} = \text{cantidad} \times \text{precio\_unitario}$  (redondeado a 2 decimales).
- $\text{subtotal\_pedido} = \text{suma de todos los subtotal\_linea de las líneas que integran el mismo pedido.}$
- $\text{impuestos} = \text{subtotal\_pedido} \times 0.16$  (redondeado a 2 decimales), es decir, una tasa fija de 16%.
- $\text{total\_pedido} = \text{subtotal\_pedido} + \text{impuestos}$  (redondeado a 2 decimales).

Esta fórmula se verificó directamente sobre las 3,754 filas del dataset limpio y sobre los 1,500 pedidos que agrupan: en el 100% de los casos, `subtotal_linea` coincide exactamente con `cantidad × precio_unitario`, `subtotal_pedido` coincide con la suma de las líneas del pedido, e `impuestos` y `total_pedido` coinciden con el cálculo de la tasa de 16% descrita arriba, sin excepciones.

## 6.8 Promociones y descuentos

El script de generación no contempla ningún mecanismo de promociones ni de descuentos: no existe una variable de promoción, ni una variable de descuento, ni ninguna regla que reduzca el subtotal o el total de un pedido por este concepto. En consecuencia, el total de cada pedido siempre equivale a `subtotal_pedido` más impuestos, sin ajustes adicionales. Esta sección se reporta, conforme a los archivos proporcionados, como No determinado a partir de los archivos proporcionados en lo relativo a la existencia de promociones o descuentos.

## 6.9 Métodos de pago

El canal de venta (`canal_venta`) se determina antes que el método de pago y sigue una regla dependiente del tiempo: antes del lanzamiento de la página web (1 de julio de 2025), todos los pedidos se distribuyen entre los dos canales presenciales (Presencial (mostrador) y Presencial (mesero)) con pesos de 55% y 45% respectivamente. A partir del lanzamiento de la web, la participación del canal "Página web" crece de forma progresiva conforme avanza el tiempo desde esa fecha: el peso asignado a la web comienza en 25% y aumenta hasta un máximo aproximado de 70% al cumplirse un año desde el lanzamiento, repartiéndose el resto proporcionalmente entre los dos canales presenciales.

El método de pago (`metodo_pago`) depende del canal: si el pedido se realizó por "Página web", existe un 85% de probabilidad de que el método sea "pago en línea"; en cualquier otro caso (incluyendo el 15% restante de los pedidos web), el método se elige de forma aleatoria uniforme entre efectivo, tarjeta y transferencia. El estado del pago (`estado_pago`) es "pagado" siempre que el pedido no esté cancelado; si el pedido está cancelado, el estado de pago se elige aleatoriamente entre "pendiente" y "reembolsado".

## 6.10 Empleados

El script de generación no incluye ninguna variable que identifique a un empleado responsable de la venta, ni ninguna regla de asignación de personal a los pedidos. Esta variable se reporta como No determinado a partir de los archivos proporcionados.

## 6.11 Tiempo de entrega

El tiempo de entrega (`tiempo_entrega_min`) se genera como un entero aleatorio uniforme entre 8 y 45 minutos, únicamente cuando el estado del pedido (`estado_pedido`) es "entregado" o "listo"; para pedidos en estado "en preparación" o "cancelado", el valor queda vacío, ya que conceptualmente el pedido aún no ha sido entregado o no llegó a completarse. El dataset limpio confirma este rango: los valores observados van de 8 a 45 minutos.

## 6.12 Calificación

La calificación del servicio (`calificacion_servicio`) solo se genera cuando el estado del pedido es "entregado"; en cualquier otro estado el valor queda vacío, bajo la lógica de que un cliente únicamente puede calificar un pedido que efectivamente recibió. Los valores permitidos van de 1 a 5, con las siguientes probabilidades: 5 estrellas (45%), 4 estrellas (30%), 3 estrellas (15%), 2 estrellas (7%) y 1 estrella (3%). Esta distribución está sesgada deliberadamente hacia calificaciones altas, y el dataset limpio confirma que los valores observados se encuentran siempre en el rango de 1 a 5, sin excepciones.

## 7. Explicación de tendencias y estacionalidad

---

Para fines de este documento se distingue entre tendencia (comportamiento que aumenta, disminuye o cambia de forma sostenida a lo largo del tiempo) y estacionalidad (comportamiento que se repite en función de un periodo determinado, como el mes, el día de la semana o la hora).

### 7.1 Tendencia creciente en el número de pedidos por mes

El dataset limpio muestra una tendencia claramente creciente en el número de pedidos por mes, pasando de valores muy bajos en los primeros meses de 2025 (1 pedido en enero, 5 en febrero) hasta valores de más de 200 pedidos mensuales hacia julio y agosto de 2026 (ver tabla de la sección 5.1). Es importante precisar que esta tendencia no proviene de una regla explícita del tipo "generar más pedidos en meses posteriores": el código selecciona la fecha de cada pedido de forma uniforme dentro de un rango. Sin embargo, ese rango depende de la fecha de registro del cliente, y como las fechas de registro de los 250 clientes se distribuyen de forma uniforme a lo largo de todo el periodo (enero 2025 a agosto 2026), en promedio los clientes solo pueden generar pedidos a partir de fechas ubicadas, en su mayoría, hacia la mitad o el final del periodo. El resultado es una tendencia creciente que emerge de la combinación de dos reglas (fecha de registro del cliente y restricción de que no haya pedidos antes del registro), y no de una tendencia programada de forma directa.

### 7.2 Tendencia creciente y explícita en la participación del canal web

A diferencia del punto anterior, la creciente participación del canal "Página web" sí corresponde a una regla explícitamente codificada: antes del 1 de julio de 2025 la web no existe como canal (0% de participación), y a partir de esa fecha su peso relativo se calcula en función de los días transcurridos desde el lanzamiento, subiendo de 25% hasta un máximo aproximado de 70%. Esto se confirma en el dataset limpio: la participación mensual del canal web pasa de 0% antes de julio de 2025, a 11.8% en julio de 2025 (mes del lanzamiento), y continúa creciendo de forma irregular hasta ubicarse entre 60% y 72% en los meses de 2026 más recientes.

### 7.3 Ausencia de estacionalidad semanal y horaria diseñada

El dataset limpio muestra una distribución de pedidos por día de la semana relativamente pareja (entre 194 pedidos el domingo y 236 el martes) y una distribución por hora también relativamente uniforme entre las 7:00 y las 20:00 horas (entre 90 y 126 pedidos por hora). Estas variaciones son consistentes con lo esperado de una selección puramente aleatoria uniforme, tal como está implementada en el código (ver secciones 6.1 y 6.2): no existe ninguna regla que favorezca un día de la semana o una hora específica como de mayor actividad. Por lo tanto, no debe interpretarse ninguna diferencia entre días u horas como una estacionalidad real del negocio; se trata de variación producto del azar sobre un muestreo uniforme.

### 7.4 Distribución de categorías y productos

Dado que tanto la categoría como el producto de cada línea se seleccionan de forma aleatoria uniforme (sección 6.4), ningún producto o categoría está diseñado para venderse más que otro en cantidad de unidades; las pequeñas diferencias observadas (por ejemplo, Frappé de café con 352 unidades vendidas frente a Ensalada César con 292) corresponden a variación aleatoria propia del muestreo. En cambio, al analizar el importe generado por categoría (subtotal\_linea acumulado), Alimentos es la categoría con mayor monto total (\$88,484.63), seguida de Café frío (\$64,312.74); esta diferencia en monto sí es explicable por una regla de diseño: el rango de precio unitario de Alimentos (\$45.00–\$95.00) es considerablemente más alto que el del resto de las categorías, por lo que su participación en el monto total de ventas es mayor aunque no se venda más en unidades.

## 8. Validación de relaciones entre variables

---

Con base en el dataset limpio y en las restricciones definidas en script\_tablas.sql y script\_triggers.sql, se verificaron las siguientes relaciones lógicas entre variables.

### 8.1 Identificación

- id\_venta es único en el 100% de las 3,754 filas del dataset limpio, consistente con su definición como llave primaria autoincremental (AUTO\_INCREMENT PRIMARY KEY) en la tabla Detalle\_pedido del script\_tablas.sql.
- No existen filas sin id\_venta o sin id\_pedido, congruente con que ambos campos están definidos como NOT NULL en el modelo relacional.

### 8.2 Fecha

- La fecha mínima observada (03 de enero de 2025) es posterior a FECHA\_INICIO (01 de enero de 2025) y la fecha máxima (19 de agosto de 2026) coincide exactamente con FECHA\_FIN, confirmando que el generador respeta el rango temporal definido.
- El campo mes y el campo día de la semana no existen como columnas independientes en el dataset: ambos se derivan matemáticamente de fecha\_pedido al momento del análisis, por lo que su correspondencia con la fecha está garantizada por construcción y no requiere validación adicional.

### 8.3 Producto

- Cada producto observado en el dataset pertenece únicamente a la categoría con la que fue generado (por ejemplo, "Latte" siempre aparece bajo la categoría "Café caliente"), consistente con la relación FK id\_categoria → Categoria\_producto definida en script\_tablas.sql para la tabla Producto.
- El precio unitario de cada producto siempre se ubica dentro del rango definido para su categoría (sección 6.6), y en ningún caso se observó un precio unitario negativo o en cero en el dataset limpio.

### 8.4 Cantidad y precio

- La cantidad observada en el dataset limpio se ubica siempre entre 1 y 3 unidades, sin valores nulos, negativos ni fuera de ese rango.
- El precio unitario observado va de \$20.03 a \$94.99, sin valores negativos, coherente con la unión de los seis rangos por categoría definidos en el generador.

### 8.5 Total

- Se verificó, para las 3,754 líneas y los 1,500 pedidos del dataset limpio, que subtotal\_linea = cantidad × precio\_unitario, que subtotal\_pedido es igual a la suma de las líneas de cada pedido, y que impuestos y total\_pedido corresponden exactamente a la fórmula de la sección 6.7, sin ninguna excepción.

### 8.6 Promoción

No aplica: al no existir variables de promoción ni de descuento en el dataset (sección 6.8), no fue posible ni necesario validar una relación entre estos campos y el total del pedido.

### 8.7 Cliente

- El tipo\_cliente asignado a cada línea corresponde exactamente al número real de pedidos que tiene ese cliente en todo el dataset, conforme a la regla de clasificación descrita en la sección 6.3; no se observaron inconsistencias entre ambos valores.
- Las variables de edad y género no están presentes en el dataset ni en el código, por lo que no fue posible validar relación alguna con estos campos.

### 8.8 Otros campos

- metodo\_pago: se validó que, cuando canal\_venta es "Página web", el método "pago en línea" predomina de forma consistente con el 85% definido en el código (sección 6.9).
- tiempo\_entrega\_min: se validó que únicamente tiene valor cuando estado\_pedido es "entregado" o "listo", y que se encuentra siempre dentro del rango de 8 a 45 minutos.
- calificacion\_servicio: se validó que únicamente tiene valor cuando estado\_pedido es "entregado", y que se encuentra siempre en el rango de 1 a 5.
- No se validó la asignación de empleado por no existir esta variable en los archivos proporcionados.

## 9. Reglas de integridad y consistencia

La siguiente tabla resume las reglas verificables mediante los archivos proporcionados (generador de datos, dataset limpio, script\_tablas.sql y script\_triggers.sql) que deben cumplirse para considerar válido un registro.

| Regla | Variable(s) involucradas             | Condición esperada                                                                                                                  | Propósito                                                                                                 |
|-------|--------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| R1    | id_venta                             | Debe ser único en todo el dataset.                                                                                                  | Garantizar que cada línea de detalle sea identificable individualmente.                                   |
| R2    | id_pedido, fecha_pedido, hora_pedido | No pueden ser nulos en ningún registro.                                                                                             | Asegurar que todo pedido esté completamente identificado y ubicado en el tiempo.                          |
| R3    | fecha_pedido                         | Debe ubicarse entre el 01-ene-2025 y el 19-ago-2026, y no ser anterior a fecha_registro_cliente del mismo cliente.                  | Evitar pedidos anteriores al inicio de operaciones o a la existencia del cliente.                         |
| R4    | categoria_producto, producto         | El producto debe pertenecer al catálogo definido para su categoría.                                                                 | Mantener la relación producto–categoría definida en el modelo relacional (Producto → Categoría_producto). |
| R5    | cantidad                             | Debe ser un entero entre 1 y 3.                                                                                                     | Evitar cantidades nulas, negativas o absurdas en una línea de pedido.                                     |
| R6    | precio_unitario                      | Debe ubicarse dentro del rango definido para la categoría del producto (sección 6.6).                                               | Evitar precios negativos o incoherentes con el catálogo.                                                  |
| R7    | subtotal_linea                       | Debe ser igual a cantidad × precio_unitario.                                                                                        | Garantizar la coherencia aritmética del importe de cada línea.                                            |
| R8    | subtotal_pedido                      | Debe ser igual a la suma de subtotal_linea de todas las líneas del mismo id_pedido.                                                 | Garantizar que el importe del pedido refleje correctamente sus líneas.                                    |
| R9    | impuestos, total_pedido              | $\text{impuestos} = \text{subtotal\_pedido} \times 0.16$ ;<br>$\text{total\_pedido} = \text{subtotal\_pedido} + \text{impuestos}$ . | Garantizar la coherencia del                                                                              |

| Regla | Variable(s) involucradas              | Condición esperada                                                                              | Propósito                                                                                 |
|-------|---------------------------------------|-------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
|       |                                       |                                                                                                 | cálculo fiscal y del total a cobrar.                                                      |
| R10   | id_mesa, ubicacion_mesa, tipo_mesa    | Solo pueden tener valor si tipo_pedido es "en el lugar"; deben ser nulos si es "para llevar".   | Evitar mesas asignadas a pedidos para llevar.                                             |
| R11   | fecha_reservacion, estado_reservacion | Solo pueden tener valor si con_reservacion es verdadero.                                        | Evitar datos de reservación en pedidos sin reservación asociada.                          |
| R12   | tiempo_entrega_min                    | Solo puede tener valor (entre 8 y 45) si estado_pedido es "entregado" o "listo".                | Evitar tiempos de entrega en pedidos que no han sido entregados.                          |
| R13   | calificacion_servicio                 | Solo puede tener valor (entre 1 y 5) si estado_pedido es "entregado".                           | Evitar calificaciones sobre pedidos no entregados.                                        |
| R14   | tipo_cliente                          | Debe corresponder al número real de pedidos históricos del cliente (sección 6.3).               | Mantener coherencia entre la segmentación declarada y el comportamiento real del cliente. |
| R15   | Bitacora (a nivel de base de datos)   | No admite operaciones UPDATE ni DELETE (trg_bitacora_block_update y trg_bitacora_block_delete). | Preservar la inalterabilidad histórica de los registros de auditoría.                     |

## 10. Ejemplos de registros válidos

A continuación se presenta un ejemplo real, tomado del dataset limpio, correspondiente al pedido con id\_pedido = 1004, integrado por tres líneas de producto.

| Producto       | Categoría  | Cantidad | Precio unitario | Subtotal de línea |
|----------------|------------|----------|-----------------|-------------------|
| Concha         | Repostería | 3        | \$45.23         | \$135.69          |
| Cold brew      | Café frío  | 2        | \$54.70         | \$109.40          |
| Frappé de café | Café frío  | 1        | \$45.50         | \$45.50           |

Datos generales del pedido: canal\_venta = Presencial (mostrador); tipo\_pedido = en el lugar; metodo\_pago = tarjeta; estado\_pedido = listo; subtotal\_pedido = \$290.59; impuestos = \$46.49;

total\_pedido = \$337.08; tiempo\_entrega\_min = 25; calificacion\_servicio = vacío (no aplica, ya que el pedido está "listo" y no "entregado"); tipo\_cliente = VIP.

El registro es coherente porque: (1) la suma de los tres subtotales de línea ( $135.69 + 109.40 + 45.50 = 290.59$ ) coincide exactamente con subtotal\_pedido; (2) los impuestos equivalen al 16% de ese subtotal ( $290.59 \times 0.16 = 46.49$ ); (3) el total equivale a la suma de subtotal e impuestos ( $290.59 + 46.49 = 337.08$ ); (4) al tratarse de un pedido "en el lugar", el registro cuenta con mesa asociada; y (5) al no estar en estado "entregado", el campo calificacion\_servicio permanece vacío, conforme a la regla de la sección 6.12.

Un segundo ejemplo permite ilustrar el efecto del canal web sobre el método de pago: el registro con id\_venta = 1 corresponde al id\_pedido = 1001, del cliente Estefanía Sánchez, canal\_venta = Presencial (mesero), tipo\_pedido = para llevar, con producto Té chai (Bebidas calientes), cantidad = 3, precio\_unitario = \$34.81 y subtotal\_linea = \$104.43. El pedido completo (cuatro líneas: Té chai, Sandwich club, Brownie y Café helado) tiene subtotal\_pedido = \$572.34, impuestos = \$91.57 y total\_pedido = \$663.91, pagado con tarjeta, con estado\_pedido = entregado, tiempo\_entrega\_min = 41 y calificacion\_servicio = 5, para un cliente clasificado como VIP. Al no haberse originado en el canal web, el método de pago no está sujeto a la regla del 85% de pago en línea, sino que se seleccionó entre efectivo, tarjeta y transferencia.

## 11. Consideraciones y limitaciones de la simulación

---

- Los datos del dataset son enteramente simulados: no representan ventas reales de Café Cereza, ya que el negocio se encuentra en una etapa previa a la operación, por lo que ningún indicador calculado a partir de ellos debe interpretarse como un resultado histórico real del negocio.
- Los patrones observados dependen por completo de las reglas y probabilidades programadas en generar\_dataset\_ventas.py; si dichas reglas cambiaran (por ejemplo, los pesos de canal de venta o los rangos de precio), los patrones resultantes del dataset cambiarían en la misma medida.
- La simulación utiliza principalmente selecciones aleatorias uniformes para variables como hora, categoría, producto y día (a través de la fecha), lo que simplifica el comportamiento real de los clientes: en un negocio real, la demanda suele concentrarse en ciertas horas, días o productos, comportamiento que este generador no reproduce de forma explícita salvo en el caso del canal de venta y de la calificación del servicio.
- La tendencia creciente en el número de pedidos por mes (sección 7.1) es, en gran medida, un efecto emergente de la forma en que se generan las fechas de registro y de pedido, y no necesariamente una representación intencional del crecimiento real de un negocio; debe interpretarse dentro de este contexto y no como una proyección de crecimiento.
- Cinco variables mencionadas como relevantes en el alcance original del análisis (edad, género, promoción, descuento y empleado) no están presentes en los archivos revisados, por lo que cualquier análisis posterior que las requiera deberá basarse en información adicional que no forma parte de este dataset.
- Los resultados de tendencias y distribuciones aquí documentados corresponden únicamente al dataset limpio; el dataset sucio debe usarse exclusivamente como insumo de práctica para procesos de limpieza y no como fuente de indicadores.



## 12. Conclusión

---

Este documento describió las reglas empleadas para generar el dataset simulado de ventas de Café Cereza, integrado por 3,754 líneas de detalle correspondientes a 1,500 pedidos y 250 clientes, cubriendo el periodo del 1 de enero de 2025 al 19 de agosto de 2026. Se documentó, variable por variable, la lógica de generación implementada en el código, distinguiendo entre reglas explícitas (como los rangos de precio por categoría, la fórmula del total del pedido o el crecimiento programado del canal web) y patrones emergentes que resultan de la interacción entre reglas (como la tendencia creciente en el número de pedidos por mes).

Documentar estas reglas de forma explícita es importante porque permite que cualquier persona que utilice el dataset comprenda qué comportamientos fueron diseñados deliberadamente y cuáles son producto de la aleatoriedad del generador, evitando interpretaciones erróneas al momento de construir indicadores o dashboards. Asimismo, la validación de relaciones aritméticas y lógicas entre variables (secciones 6.7, 8 y 9) confirma que el dataset limpio es internamente consistente y respeta las restricciones definidas en el modelo relacional de la base de datos (`script_tablas.sql` y `script_triggers.sql`).

Con esta documentación, el dataset queda preparado para las siguientes etapas del proyecto: limpieza de datos (utilizando `dataset_ventas_sucio.csv` como caso de práctica), análisis exploratorio, cálculo de indicadores de negocio y construcción de dashboards, contando con una base sólida y transparente sobre el origen y el significado de cada variable.