

CAFÉ CEREZA

- Página web con sistema de reservaciones para una cafetería universitaria -



Analítica de Datos para Negocios Digitales

Reporte de Calidad de Datos – Café Cereza

Evaluación cuantitativa del estado previo, referencia ideal y resultado real del proceso ETL

Elemento	Archivo / fuente
Estado previo al ETL	dataset_ventas_sucio.csv
Referencia/control	dataset_ventas_limpio.csv
Salida real del proceso	dataset_maestro_limpio.csv
Proceso de transformación	Limpieza_Cafetería
Reglas de generación	generar_dataset_ventas.py
Modelo y diccionario	Diccionario_Datos_Cafeteria.docx
Modelo físico	script_tablas.sql
Controles de auditoría	script_triggers.sql

Fecha de evaluación: 20 de agosto de 2026.

1. Introducción

La calidad de los datos es un requisito directo para que Café Cereza pueda construir indicadores, análisis históricos y dashboards confiables. Un error en cantidades, precios, categorías, estados, fechas o relaciones entre variables puede alterar métricas como ventas, ticket promedio, participación del canal web, tiempos de entrega, calificaciones y comportamiento de clientes. Por ello, la evaluación no se limita a comprobar que el archivo final tenga menos errores visibles: también verifica si el proceso conserva la información necesaria y si las eliminaciones realizadas están justificadas.

El análisis distingue tres estados: el dataset sucio como entrada previa al ETL; el dataset de ventas limpio como referencia ideal generada antes de insertar errores; y el dataset maestro limpio como salida real del proceso implementado. La referencia ideal se utiliza como control y no se confunde con el resultado del ETL.

2. Objetivo

Evaluar cuantitativamente la calidad antes y después del proceso de transformación, contrastar el resultado con la referencia ideal y determinar si la limpieza mejora completitud, unicidad, validez, consistencia e integridad sin provocar pérdida injustificada de información.

3. Descripción de datasets

Métrica	Dataset sucio	Referencia ideal	Resultado ETL
Filas	3,941	3,754	247
Columnas	31	31	29
Pedidos únicos	1,500	1,500	247
Clientes	250	250	244 identificadores anonimizados
Periodo temporal	03/01/2025–19/08/2026	03/01/2025–19/08/2026	04/03/2025–19/08/2026
Nulos totales	15,161	12,891	869
Filas exactamente duplicadas	26	0	0
IDs de venta repetidos (exceso sobre únicos)	187	0	0

Los nulos totales incluyen ausencias legítimas en campos condicionales, por ejemplo mesa en pedidos para llevar, datos de reservación cuando no existe reservación, tiempo de entrega según estado y calificación cuando el pedido no fue entregado. Por esa razón, el total bruto de nulos no debe interpretarse por sí solo como cantidad de errores.

4. Dimensiones de calidad

4.1 Completitud

Para una comparación homogénea se evaluaron 21 campos analíticos presentes en los tres archivos y esperados en cada fila: identificadores de venta/pedido, fecha de registro, canal, categoría, producto, cantidad, precio, subtotal de línea, tipo de pedido, indicador de reservación, fecha y hora de pedido, estado de pedido, método y estado de pago, subtotal del pedido, impuestos, total, tipo de cliente y origen e-commerce. Se excluyeron de esta métrica los campos condicionales y los datos personales retirados por anonimización.

Dataset	Valores presentes	Valores esperados	Nulos	Completitud
Sucio	82,116	82,761	645	99.22%
Referencia ideal	78,834	78,834	0	100.00%
Resultado ETL	5,134	5,187	53	98.98%

La completitud comparable no mejora: pasa de 99.22% a 98.98%. Esto ocurre porque el proceso conserva algunas filas con precio, producto o método de pago ausentes y además la conversión de fecha_registro_cliente produce cuatro valores nulos.

4.2 Unicidad

La clave id_venta representa un renglón de venta y debe identificar de forma única cada fila. El dataset sucio contiene 3,754 IDs de venta únicos en 3,941 filas; por tanto, 187 filas exceden la unicidad de ese identificador. De ellas, 26 son duplicados completos. La referencia ideal y el resultado ETL presentan 100.00% de unicidad de id_venta. La repetición de id_pedido es legítima porque un pedido puede contener varios productos; igualmente, la repetición de cliente, correo, producto o categoría no constituye por sí misma un duplicado.

4.3 Validez

Las reglas de validez se tomaron del generador, el diccionario y el modelo físico. Entre ellas se encuentran cantidades de 1 a 3 en el dataset generado, precios dentro del intervalo definido por categoría, calificación de 1 a 5, tiempo generado entre 8 y 45 minutos cuando aplica, dominios documentados de canal/categoría/estado y fechas dentro del periodo de generación. El modelo relacional además define tipos de datos, obligatoriedad, claves y dominios específicos de algunas entidades.

4.4 Consistencia

Se comprobaron relaciones matemáticas y lógicas documentadas: subtotal_linea = cantidad × precio_unitario; impuestos = 16% del subtotal_pedido; total_pedido = subtotal_pedido + impuestos; correspondencia producto–categoría; mesa según tipo de pedido; reservación según tipo de pedido; origen_ecommerce según canal; pago en línea asociado al canal web; estados de pedido y pago; presencia de calificación y tiempo de entrega según estado; y orden temporal entre registro, reservación y pedido.

4.5 Integridad

El modelo de base de datos establece claves primarias y foráneas para Usuario, Mesa, Reservación, Producto, Pedido, Detalle de pedido y Pago. En el dataset aplanado pueden comprobarse de forma directa los identificadores de venta, pedido y cliente, pero no están presentes todas las tablas maestras necesarias para validar físicamente cada clave foránea contra su tabla de origen. Por tanto, la integridad referencial completa es: No determinado a partir de los archivos proporcionados. Sí se comprobó que el resultado ETL conserva 247 id_venta que existen en la referencia ideal y no introduce IDs de venta nuevos.

5. Valores nulos

Campo	Sucio	Referencia ideal	Resultado ETL
id_venta	0 (0.00%)	0 (0.00%)	0 (0.00%)
id_pedido	0 (0.00%)	0 (0.00%)	0 (0.00%)
id_cliente	0 (0.00%)	0 (0.00%)	Retirado por anonimización
nombre_cliente	85 (2.16%)	0 (0.00%)	Retirado por anonimización
correo_cliente	353 (8.96%)	0 (0.00%)	Retirado por anonimización
fecha_registro_cliente	0 (0.00%)	0 (0.00%)	4 (1.62%)
canal_venta	0 (0.00%)	0 (0.00%)	0 (0.00%)
categoria_producto	0 (0.00%)	0 (0.00%)	0 (0.00%)
producto	82 (2.08%)	0 (0.00%)	5 (2.02%)
cantidad	0 (0.00%)	0 (0.00%)	0 (0.00%)
precio_unitario	280 (7.10%)	0 (0.00%)	20 (8.10%)
subtotal_linea	0 (0.00%)	0 (0.00%)	0 (0.00%)
tipo_pedido	0 (0.00%)	0 (0.00%)	0 (0.00%)
con_reservacion	0 (0.00%)	0 (0.00%)	0 (0.00%)
id_mesa	1,906 (48.36%)	1,822 (48.53%)	120 (48.58%)
ubicacion_mesa	2,051 (52.04%)	1,822 (48.53%)	127 (51.42%)
tipo_mesa	1,906 (48.36%)	1,822 (48.53%)	120 (48.58%)
fecha_reservacion	2,986 (75.77%)	2,843 (75.73%)	184 (74.49%)
estado_reservacion	3,060 (77.65%)	2,843 (75.73%)	186 (75.30%)
fecha_pedido	0 (0.00%)	0 (0.00%)	0 (0.00%)

hora_pedido	0 (0.00%)	0 (0.00%)	0 (0.00%)
estado_pedido	0 (0.00%)	0 (0.00%)	0 (0.00%)
metodo_pago	283 (7.18%)	0 (0.00%)	24 (9.72%)
estado_pago	0 (0.00%)	0 (0.00%)	0 (0.00%)
subtotal_pedido	0 (0.00%)	0 (0.00%)	0 (0.00%)
impuestos	0 (0.00%)	0 (0.00%)	0 (0.00%)
total_pedido	0 (0.00%)	0 (0.00%)	0 (0.00%)
tiempo_entrega_min	837 (21.24%)	592 (15.77%)	0 (0.00%)
calificacion_servicio	1,332 (33.80%)	1,147 (30.55%)	79 (31.98%)
tipo_cliente	0 (0.00%)	0 (0.00%)	0 (0.00%)
origen_ecommerce	0 (0.00%)	0 (0.00%)	0 (0.00%)

El valor 0% de nulos en tiempo_entrega_min del resultado ETL no representa necesariamente una mejora: el proceso sustituye todos los nulos por 15, aun cuando la referencia ideal conserva nulos legítimos para estados donde el tiempo no aplica. En cambio, producto, precio_unitario y metodo_pago permanecen incompletos en parte de las filas retenidas.

6. Duplicados

Tipo	Sucio	Referencia ideal	Resultado ETL	Interpretación
Filas exactamente duplicadas	26	0	0	Duplicidad real de fila completa.
id_venta repetido: filas excedentes	187	0	0	Inconsistencia del identificador único de renglón.
id_pedido repetido	Sí	Sí	No en la muestra retenida	Es legítimo: un pedido puede tener varios renglones de producto.
Cliente/correo repetido	Sí	Sí	Muy reducido	Es legítimo: un cliente puede realizar varios pedidos.
Producto/categoría repetidos	Sí	Sí	Sí	Es legítimo: son dimensiones reutilizadas en ventas distintas.

El proceso elimina primero los duplicados completos, lo cual es coherente con los 26 registros idénticos detectados. Después aplica una eliminación por correo_cliente conservando únicamente la primera aparición. Este segundo criterio no identifica duplicados de venta; identifica múltiples transacciones del mismo cliente y, por tanto, elimina repetición legítima.

7. Valores inválidos

Campo	Regla	Sucio	Referencia	Resultado ETL
cantidad	1–3 unidades según el generador	141 (3.58%)	0 (0.00%)	9 (3.64%)
precio_unitario	Rango por categoría: 28–55, 35–65, 25–60, 45–95, 20–40 o 25–45	155 (3.93%)	0 (0.00%)	13 (5.26%)
calificacion_servicio	1–5 cuando existe	141 (3.58%)	0 (0.00%)	9 (3.64%)
tiempo_entrega_min	8–45 min cuando existe en el generador	94 (2.39%)	0 (0.00%)	4 (1.62%)
cana_venta	Página web / Presencial (mostrador) / Presencial (mesero)	150 (3.81%)	0 (0.00%)	9 (3.64%)
categoria_producto	Seis categorías del catálogo del generador	291 (7.38%)	0 (0.00%)	21 (8.50%)
estado_pedido	entregado / listo / en preparación / cancelado	57 (1.45%)	0 (0.00%)	4 (1.62%)
fecha_pedido	Fecha interpretable dentro del periodo; formato ideal ISO YYYY-MM-DD	391 no ISO (9.92%)	0 no ISO	29 no ISO (11.74%)
fecha_registro_cliente	Formato ideal ISO YYYY-MM-DD	409 no ISO (10.38%)	0 no ISO	0 no ISO entre valores presentes; 4 nulos creados
fecha_reservacion	Formato ideal ISO cuando existe	102 no ISO	0 no ISO	7 no ISO

con_reservacion	Booleano canónico verdadero/falso	113 (2.87%)	0 (0.00%)	6 (2.43%)
origen_ecommerce	Booleano verdadero/falso	0 (0.00%)	0 (0.00%)	0 (0.00%)

Los porcentajes de esta tabla usan el total de filas del dataset correspondiente para facilitar la comparación. En campos opcionales, la ausencia no se contabiliza como valor inválido. La limpieza no corrige de forma general cantidades, precios, categorías, canales, estados ni formatos de fecha de pedido/reservación; varios errores permanecen en las 247 filas retenidas.

8. Consistencia matemática

Validación	Sucio: correctos / total	Referencia: correctos / total	ETL: correctos / total
subtotal_linea = cantidad × precio_unitario	3,371 / 3,941 (85.54%)	3,754 / 3,754 (100.00%)	206 / 247 (83.40%)
impuestos = subtotal_pedido × 0.16	3,826 / 3,941 (97.08%)	3,754 / 3,754 (100.00%)	237 / 247 (95.95%)
total_pedido = subtotal_pedido + impuestos	3,826 / 3,941 (97.08%)	3,754 / 3,754 (100.00%)	237 / 247 (95.95%)
subtotal_pedido = suma de subtotales de sus líneas	1,273 / 1,500 pedidos (84.87%)	1,500 / 1,500 (100.00%)	30 / 247 pedidos (12.15%)

Las fórmulas provienen del generador y del diccionario: subtotal_linea se calcula como cantidad × precio_unitario; el generador aplica 16% de impuestos; y total_pedido es subtotal_pedido + impuestos. El resultado ETL conserva errores matemáticos de las filas sucias y, adicionalmente, al reducir casi todos los pedidos a una sola fila, pierde las demás líneas necesarias para reconstruir el subtotal de 217 de los 247 pedidos retenidos. Esta última inconsistencia es consecuencia directa de la pérdida de renglones, no de una fórmula nueva.

9. Consistencia entre variables

Relación verificable	Sucio	Referencia ideal	Resultado ETL
Producto ↔ categoría	3,497 / 3,776 reconocibles (92.61%)	3,754 / 3,754 (100.00%)	217 / 237 reconocibles (91.56%)
Tipo de pedido ↔ presencia de mesa	3,941 / 3,941 (100.00%)	3,754 / 3,754 (100.00%)	247 / 247 (100.00%)
Reservación ↔ campos de reservación	3,755 / 3,941 (95.28%)	3,754 / 3,754 (100.00%)	239 / 247 (96.76%)
Reservación verdadera ↔ pedido en el lugar	3,941 / 3,941 (100.00%)	3,754 / 3,754 (100.00%)	247 / 247 (100.00%)
origen_ecommerce ↔ canal_venta	3,853 / 3,941 (97.77%)	3,754 / 3,754 (100.00%)	243 / 247 (98.38%)
pago en línea → Página web	3,874 / 3,941 (98.30%)	3,754 / 3,754 (100.00%)	244 / 247 (98.79%)
estado_pedido ↔ estado_pago	3,937 / 3,941 (99.90%)	3,754 / 3,754 (100.00%)	247 / 247 (100.00%)
estado_pedido ↔ calificación	3,651 / 3,941 (92.64%)	3,754 / 3,754 (100.00%)	229 / 247 (92.71%)
estado_pedido ↔ tiempo_entrega	3,653 / 3,941 (92.69%)	3,754 / 3,754 (100.00%)	207 / 247 (83.81%)
fecha_registro ↔ fecha_pedido	3,941 / 3,941 (100.00%)	3,754 / 3,754 (100.00%)	241 / 243 comparables (99.18%)
fecha_reservacion ≤ fecha_pedido	955 / 955 (100.00%)	911 / 911 (100.00%)	63 / 63 (100.00%)

La relación pedido ↔ cliente puede comprobarse parcialmente: en la referencia cada id_pedido pertenece a un cliente, mientras que en el resultado la identidad se conserva mediante cliente_id_anon. La integridad contra tablas Usuario, Producto, Reservación, Mesa y Pago no puede comprobarse de forma completa porque el dataset aplanado no contiene las tablas maestras completas: No determinado a partir de los archivos proporcionados.

10. Comparación antes/después

Indicador	Antes ETL	Después ETL	Cambio
Filas	3,941	247	-3,694 (-93.73%)
Pedidos únicos	1,500	247	-1,253 (-83.53%)
Clientes distintos	250	244 anonimizados	-6 (-2.40%)

Duplicados exactos	26	0	-26
Unicidad de id_venta	95.26%	100.00%	+4.74 pp
Compleitud comparable	99.22%	98.98%	-0.24 pp
Categorías inválidas	291 (7.38%)	21 (8.50%)	+1.12 pp en proporción
Cantidades inválidas	141 (3.58%)	9 (3.64%)	+0.06 pp
Precios fuera del rango de categoría	155 (3.93%)	13 (5.26%)	+1.33 pp
Subtotal de línea correcto	85.54%	83.40%	-2.14 pp
Formato no ISO en fecha_pedido	9.92%	11.74%	+1.82 pp

La mejora inequívoca se concentra en la eliminación de duplicados exactos y en la unicidad de id_venta. Para varias métricas de validez y consistencia, el porcentaje del resultado no mejora y en algunos casos empeora, porque la limpieza selecciona una muestra pequeña sin corregir sistemáticamente los errores de las filas que conserva.

11. Conservación de información

Métrica	Resultado
Retención de filas = $247 / 3,941 \times 100$	6.27%
Pérdida de filas = $3,694 / 3,941 \times 100$	93.73%
Pedidos únicos conservados	247 de 1,500 (16.47%)
Pedidos únicos perdidos	1,253 de 1,500 (83.53%)
Clientes conservados	244 de 250 (97.60%)
Clientes no representados al final	6 de 250 (2.40%)
Periodo inicial	03/01/2025–19/08/2026
Periodo final	04/03/2025–19/08/2026
Cobertura temporal	Se conserva la fecha final, pero se pierden registros de enero y febrero de 2025

“Eliminado” no equivale automáticamente a “error corregido”. De las 3,694 filas eliminadas, solo una fracción corresponde a duplicados exactos o a registros filtrados por total/cantidad. La mayor reducción proviene de un criterio aplicado al correo del cliente, que no es una clave única de venta.

12. Evaluación de transformaciones destructivas

La secuencia real de reducción es determinante: 3,941 filas iniciales pasan a 3,915 al eliminar 26 duplicados exactos; después pasan a 255 al ejecutar una eliminación por correo_cliente conservando solo la primera fila por correo; finalmente, los filtros total_pedido > 0 y cantidad > 0 reducen el conjunto a 247 filas. Por tanto, la operación basada en correo elimina 3,660 filas después de quitar duplicados exactos y explica casi toda la pérdida.

El correo es único a nivel de Usuario en el modelo relacional, pero no es único a nivel de venta. Un usuario puede generar varios pedidos y un pedido puede contener varios renglones. Usar correo_cliente como criterio de deduplicación en un dataset transaccional transforma una regla válida de identidad de usuario en una regla inválida de unicidad de venta. Esto puede eliminar ventas legítimas, líneas adicionales del mismo pedido y compras recurrentes del mismo cliente.

Los filtros total_pedido > 0 y cantidad > 0 eliminan ocho filas adicionales después de la deduplicación por correo. El generador sí introduce cantidades 0 o negativas y ventas con total 0 como errores deliberados, por lo que esos criterios tienen respaldo para identificar valores problemáticos. Sin embargo, eliminar la fila completa no reconstruye el valor correcto a partir de la referencia ni distingue entre corrección y descarte. La evaluación, por tanto, considera estos filtros plausibles como control de validez, pero no contabiliza automáticamente las filas eliminadas como “errores corregidos”.

La sustitución de tiempo_entrega_min nulo por 15 también es destructiva a nivel semántico, aunque no elimine filas: convierte ausencias legítimas en un valor numérico. La referencia ideal demuestra que 592 registros debían conservar tiempo nulo. En el resultado ETL no queda ningún nulo en este campo y la consistencia estado_pedido ↔ tiempo_entrega cae a 83.81%.

13. Comparación contra la referencia ideal

El resultado ETL contiene 247 id_venta y los 247 existen en la referencia ideal; no se detectaron IDs de venta inventados. Sin embargo, representa solo 247 de las 3,754 filas ideales (6.58%) y 247 de los 1,500 pedidos ideales (16.47%). En clientes, la cobertura es mayor: 244 identificadores anonimizados corresponden a 244 de los 250 clientes originales (97.60%), pero cada cliente queda representado casi siempre por una sola fila, por lo que se pierde su historial de compras.

La anonimización de id_cliente, nombre_cliente y correo_cliente es una transformación legítima desde la perspectiva de privacidad y no se exige coincidencia textual con la referencia. No obstante, la anonimización ocurre después de la deduplicación por correo; por ello, no explica la pérdida masiva. El resultado tampoco recupera sistemáticamente las categorías, canales, cantidades, precios, calificaciones o estados alterados en la versión sucia.

Aspecto	Referencia ideal	Resultado ETL	Evaluación
Filas	3,754	247	Cobertura 6.58%
Pedidos	1,500	247	Cobertura 16.47%
Clientes	250	244 anonimizados	Cobertura 97.60%
Inicio del periodo	03/01/2025	04/03/2025	No conserva el inicio
Duplicados exactos	0	0	Coincide
Errores de dominio/rango	0 en reglas evaluadas	Persisten	No recuperado
PII de cliente	Presente	Anonimizada	Transformación legítima
Líneas completas por pedido	Sí	Mayormente no	Pérdida estructural

14. Índices de calidad

Se calculó un índice metodológico únicamente sobre criterios verificables. Completitud usa los 21 campos comparables obligatorios; unicidad usa id_venta; validez agrega dominios, rangos, fechas y booleanos documentados; consistencia agrega relaciones lógicas y matemáticas verificables. El índice no mide conservación de información, por lo que debe interpretarse junto con la retención de filas y pedidos.

Dimensión	Sucio	Referencia ideal	Resultado ETL
Completitud	99.22%	100.00%	98.98%
Unicidad (id_venta)	95.26%	100.00%	100.00%
Validez	98.03%	100.00%	97.96%
Consistencia	96.15%	100.00%	95.21%
Índice de calidad promedio	97.16%	100.00%	98.04%

Aunque el índice promedio sube de 97.16% a 98.04%, la mejora se debe principalmente a la unicidad. No es metodológicamente correcto concluir que el ETL es globalmente mejor solo por ese promedio: el resultado conserva 6.27% de las filas de entrada y 16.47% de los pedidos. Un índice de calidad de celda o regla puede aumentar mientras la cobertura informativa se deteriora de forma severa.

15. Hallazgos

Hallazgo	Evidencia	Impacto	Severidad
Pérdida masiva de registros	247 de 3,941 filas retenidas; pérdida 93.73%.	Reduce drásticamente la base analítica.	Crítica

Deduplicación por correo no corresponde a venta duplicada	3,915 → 255 filas al conservar solo el primer correo.	Elimina compras y líneas legítimas de clientes recurrentes.	Crítica
Pérdida de pedidos	247 de 1,500 pedidos conservados.	KPIs de ventas, frecuencia y tendencias dejan de representar el histórico.	Crítica
Se pierden líneas de detalle de pedidos	Solo 30 de 247 pedidos retenidos reconstruyen su subtotal con las líneas presentes.	Impide análisis correcto de cesta y productos por pedido.	Crítica
Persisten valores inválidos	21 categorías, 9 cantidades, 13 precios, 9 calificaciones y otros errores en 247 filas.	Sesga agregaciones y segmentaciones.	Alta
Tiempo nulo sustituido indiscriminadamente por 15	0 nulos finales frente a 592 nulos legítimos en referencia; consistencia final 83.81%.	Introduce tiempos ficticios en estados donde no aplica.	Alta
Fechas de pedido/reservación no se estandarizan completamente	29 fecha_pedido y 7 fecha_reservacion no ISO en el resultado.	Complica agrupación temporal y validación uniforme.	Media
Conversión de fecha de registro genera pérdida	4 fecha_registro_cliente nulas en el resultado.	Pierde fecha útil de cuatro filas.	Media
Duplicados exactos sí fueron eliminados	26 → 0.	Mejora unicidad real.	Baja
Anonimización de cliente	PII retirada y cliente_id_anon creado.	Mejora privacidad sin inventar nuevas ventas.	Baja

16. Resultado general

Mejoró la eliminación de duplicados exactos, la unicidad de id_venta y la protección de datos personales mediante anonimización. También se excluyeron, en la muestra que sobrevivió a la deduplicación por correo, algunas filas con total no positivo o cantidad no positiva.

No se corrigieron de manera sistemática categorías mal escritas, canales inconsistentes, estados alterados, cantidades fuera de rango, precios inválidos, calificaciones fuera de rango, formatos heterogéneos de fecha de pedido/reservación ni todas las inconsistencias matemáticas. Además, la imputación fija de tiempo de entrega introduce valores donde la referencia muestra que el nulo puede ser legítimo.

Sí hubo pérdida de información: 93.73% de las filas y 83.53% de los pedidos desaparecieron. La parte atribuible a 26 duplicados exactos está justificada. La reducción principal por correo_cliente no parece justificada para un dataset de ventas, porque correo identifica al usuario, no a la transacción. En consecuencia, el dataset resultante es insuficiente como dataset maestro para análisis históricos, KPIs de ventas, recurrencia, cesta de compra, estacionalidad o dashboards que pretendan representar el conjunto original. Puede servir como muestra muy reducida para pruebas técnicas, pero no como sustituto fiel del histórico.

17. Recomendaciones

- Separar la deduplicación de usuario y de venta.** Mantener correo como atributo único en la entidad Usuario, pero no usarlo para eliminar filas del dataset transaccional. Para ventas, deduplicar con id_venta o con una clave compuesta documentada cuando corresponda.
- Conservar todas las líneas legítimas por pedido.** Antes de eliminar registros, comprobar si la fila representa otro producto del mismo pedido. La relación Pedido 1:N Detalle de pedido exige múltiples renglones.
- Corregir dominios en lugar de seleccionar una muestra.** Normalizar explícitamente las variantes documentadas de categoría, canal y estado hacia sus valores canónicos.
- Aplicar validaciones de rango con trazabilidad.** Marcar y corregir cantidades, precios, calificaciones y tiempos usando las reglas verificadas; si no puede recuperarse el valor, registrar el caso en la bitácora de calidad en vez de ocultarlo mediante eliminación masiva.

5. **Estandarizar todas las fechas relevantes.** Convertir fecha_pedido, fecha_registro_cliente y fecha_reservacion a un formato único, validando pérdida por conversión.
6. **Tratar nulos según condición de negocio.** No imputar tiempo_entrega_min cuando el estado del pedido indica que el tiempo no aplica. Mantener nulo estructural o definir una regla documentada.
7. **Validar matemáticas después de la transformación.** Recalcular subtotal_linea, subtotal_pedido, impuestos y total únicamente cuando las líneas necesarias estén completas y documentar diferencias.
8. **Agregar controles de conservación.** Detener o alertar el proceso cuando la retención de filas/pedidos caiga fuera de un umbral aprobado. Comparar conteos antes/después por pedido y cliente.
9. **Validar integridad contra tablas maestras.** Cuando estén disponibles las tablas relacionales pobladas, comprobar claves foráneas de usuario, producto, mesa, reservación y pago.
10. **Conservar evidencia de cada descarte.** Registrar motivo, identificador y etapa de cada fila eliminada para diferenciar duplicado real, error no recuperable y exclusión de negocio.

18. Conclusión

El proceso ETL evaluado produce un archivo sin duplicados exactos y con anonimización de datos personales, pero no alcanza el objetivo de limpiar el histórico conservando su información. La transformación más relevante —eliminar filas repetidas por correo_cliente— no corresponde a la granularidad del dataset de ventas y provoca una pérdida crítica: se retiene 6.27% de las filas de entrada y 16.47% de los pedidos. La referencia ideal confirma que esas repeticiones de cliente forman parte de ventas legítimas y que el histórico esperado contiene 3,754 líneas y 1,500 pedidos.

Además, el resultado conserva errores de rango, dominio y consistencia matemática, no estandariza todas las fechas y reemplaza nulos legítimos de tiempo de entrega por un valor fijo. Por ello, la calidad del resultado no debe juzgarse únicamente por la ausencia de duplicados o por el índice promedio de 98.04%. Considerando simultáneamente validez, consistencia y conservación de información, el dataset maestro resultante no es adecuado como fuente definitiva para KPIs y dashboards representativos del histórico de Café Cereza hasta corregir el criterio de deduplicación y aplicar transformaciones específicas sobre los errores detectados.

19. Fuentes técnicas analizadas

- dataset_ventas_sucio.csv — estado previo al ETL.
- dataset_ventas_limpio.csv — referencia ideal/control.
- dataset_maestro_limpio.csv — salida real del proceso.
- Limpieza_Cafetería — secuencia implementada de extracción, perfilado, limpieza, anonimización y exportación.
- generar_dataset_ventas.py — reglas de generación, dominios, fórmulas y errores insertados.
- Diccionario_Datos_Cafeteria.docx — entidades, atributos, relaciones y fórmulas documentadas.
- script_tablas.sql — claves, restricciones, tipos y relaciones del modelo físico.
- script_triggers.sql — controles de auditoría y protección de bitácora.